Machine Learning

(Introdução à aprendizagem por máquina)

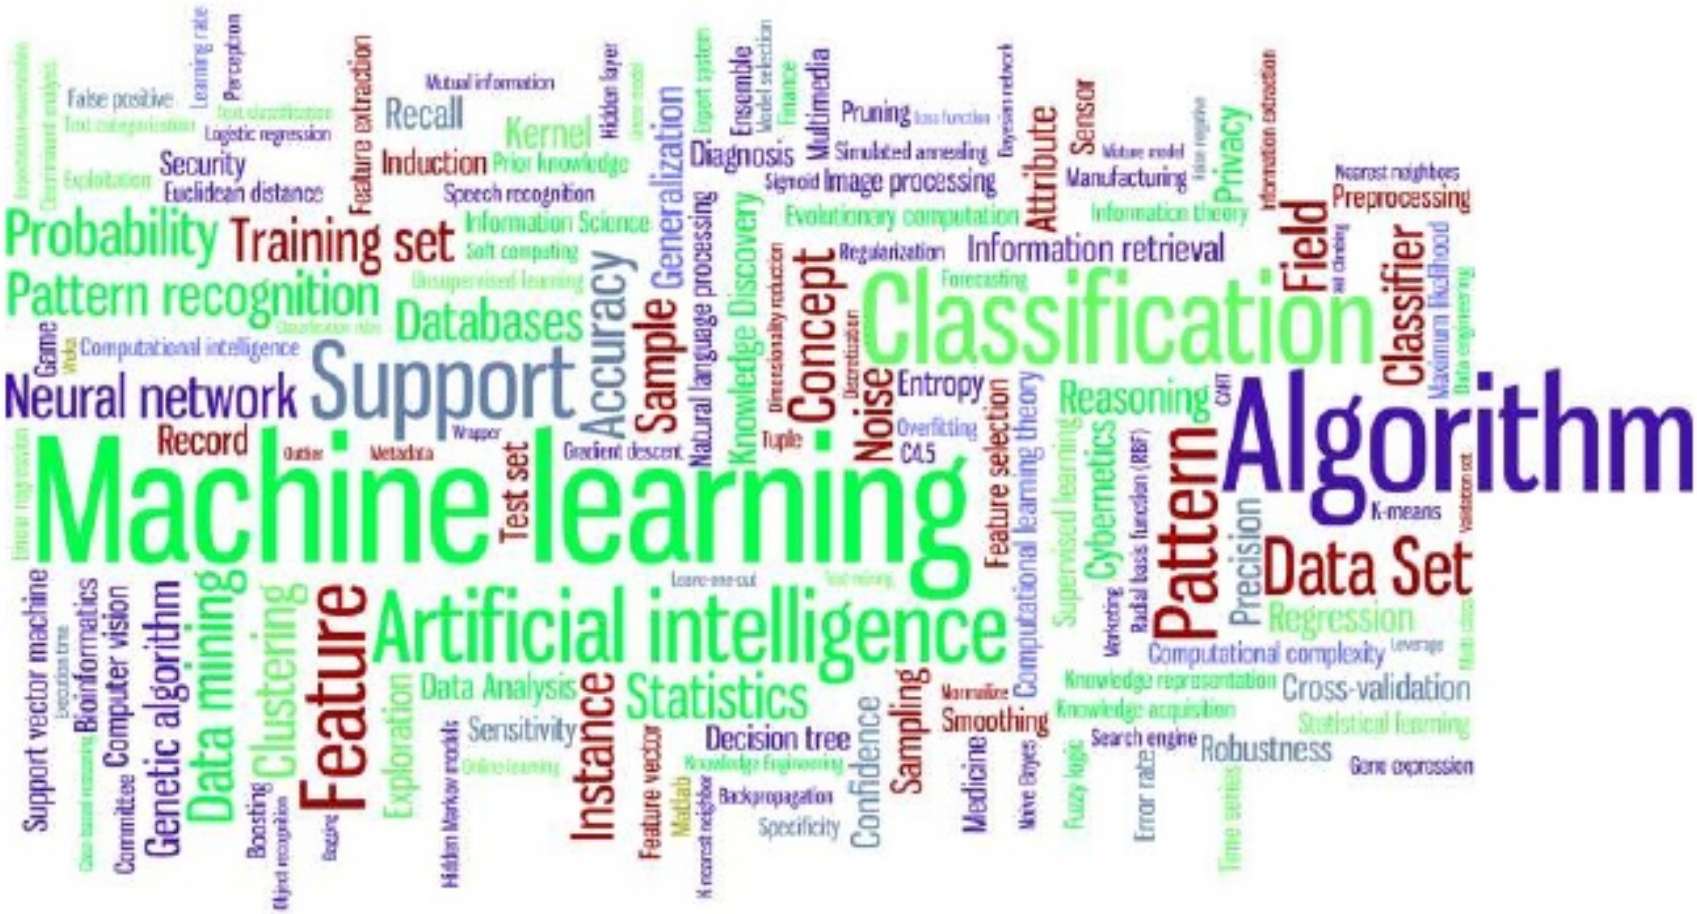

Sobre mim

Miguel Farrajota

(2004-2008) Licenciatura em Engenharia Eléctrica e Electrónica - **TIT**

(2008-2011) Mestrado em Engenharia Eléctrica e Electrónica - **TIT**

(2012-2017) Doutoramento em Engenharia Electrónica e Telecomunicações - **Processamento Sinal**

(2017+) Projecto CEOT + faculdade medicina para criar uma aplicação web para gerir dados de pacientes

Áreas de interesse:

- Visão Computacional
- Data science
- Machine learning
- Deep learning
- Python
- Automatização
- Web
- DevOps

https://github.com/farrajota

Tópicos da apresentação

- Machine Learning
- Deep Learning
- Toolboxes + Frameworks
- Recursos online

Machine Learning

Herbert Alexander Simon:

- “Aprender é qualquer processo em que um sistema melhora a sua performance através da experiência”
- “*Machine learning* preocupa-se com programas que automaticamente melhoram a sua performance através da experiência ”

Porquê aprender?

- A aprendizagem é útil quando:
  - A perícia humana não existe (p.e., navegar em marte)
  - Não somos capazes de explicar a nossa experiência (reconhecimento de voz)
  - As soluções mudam ao longo do tempo (routeamento de pacotes numa rede)
  - Soluções precisam de se adaptar para casos particulares (dados biométricos)
- *Machine learning* permite programar computadores para optimizar um critério usando dados ou experiência passada

Porquê Machine Learning?

- Desenvolver sistemas que se adaptam / customizam automaticamente a uma tarefa
  - Filtros de spam (emails)
- Descobrir novo conhecimento em grandes bases de dados (***data mining***)
  - Análise de mercados
- Habilidade de substituir tarefas monótonas
  - Reconhecer fotos e agrupá-las por categorias
- Desenvolver sistemas que são demasiado difíceis de construir ou demasiado complexos para se produzir uma solução manualmente.
  - Sistemas de navegação autónomos

Porquê agora?

- Surgimento de grandes quantidades de dados
- Aumento do processamento computacional
- Crescente progresso e desenvolvimento de algoritmos e teorias sobre o campo de aprendizagem automática
- Importância na indústria

Aplicações

Retalho: Análise de mercados, gestão de relacionamento de clientes

Finanças: Avaliação de crédito, detecção de fraude

Fabrico: Optimização, soluçionamento de problemas

Medicina: Diagnósticos médicos

Telecomunicações: Optimização de qualidade de serviço

Bioinformática: Motifs, alinhamento (DNA)

Web mining: Motores de busca

Acerca do ML

- É um subcampo da Inteligência Artificial (AI)
- Deriva do conceito que lida com a construcção e estudo de sistemas que podem aprender através de dados.
- É um conceito teórico com várias técnicas e implementações.

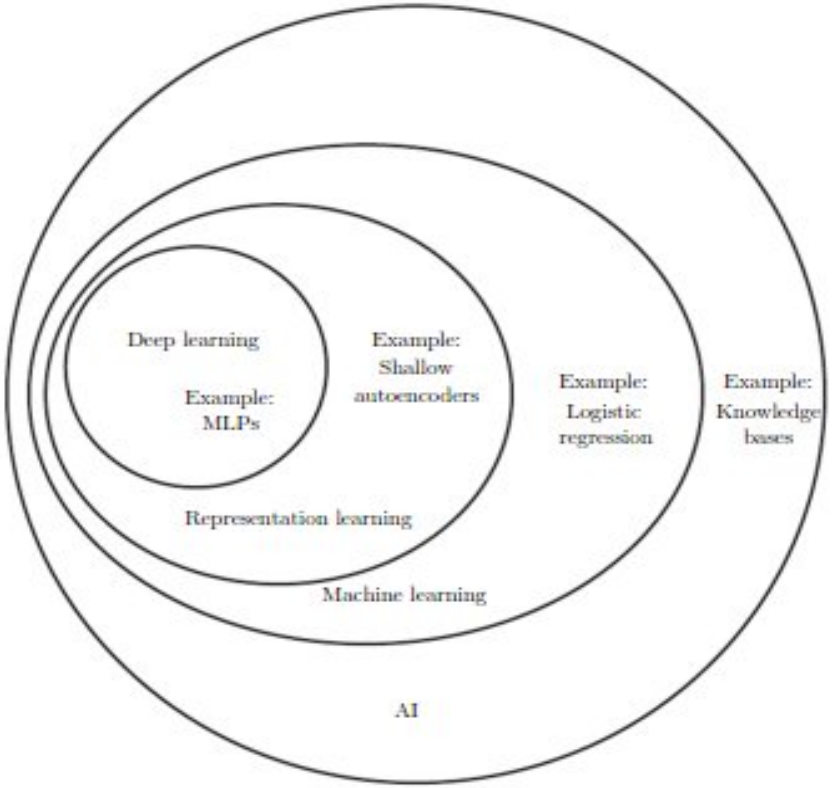

Em que consiste o ML?

- O Machine learning consiste no estudo de algoritmos que melhoram a sua performance para uma dada tarefa usando experiência (dados).
- O objectivo é optimizar um critério de performance usando dados ou experiência passada.
- Propósito em estatística: inferência a partir de uma amostra
- Propósito na informática: algoritmos eficientes para
  - Resolver o problema da optimização
  - Representar e avaliar o modelo para inferência

Crescimento do ML

- O Machine Learning é a abordagem preferida para:
  - Reconhecimento de fala (*speech recognition*)
  - Processamento de linguagem (*natural language processing*)
  - Visão computacional (*Computer vision*)
  - Análise de avaliações médicas (*medical outcomes analysis*)
  - Controlo de robôs (*robot contro*l)
- Esta moda está a acelerar
  - Melhorias dos algoritmos
  - Melhorias na captura de dados, networking, computadores mais rápidos
  - Software demasiado complexo para ser escrito à mão
  - Novos sensores / dispositivos IO
  - Exigência de customização a urtilizadores, ambientes
  - Dificuldade de conseguirmos traduzir o nosso conhecimento para a forma de um algoritmos

Exemplo de aprendizagem

Exemplo: Prever como uma pessoa irá classificar um filme

10% melhoria = prémio de 1 milhão de euros

- Essência do Machine learning:
  - Um padrão existe
  - Nós não conseguimos caracterizar matematicamente um problema
  - Temos dados sobre o problema

Solução

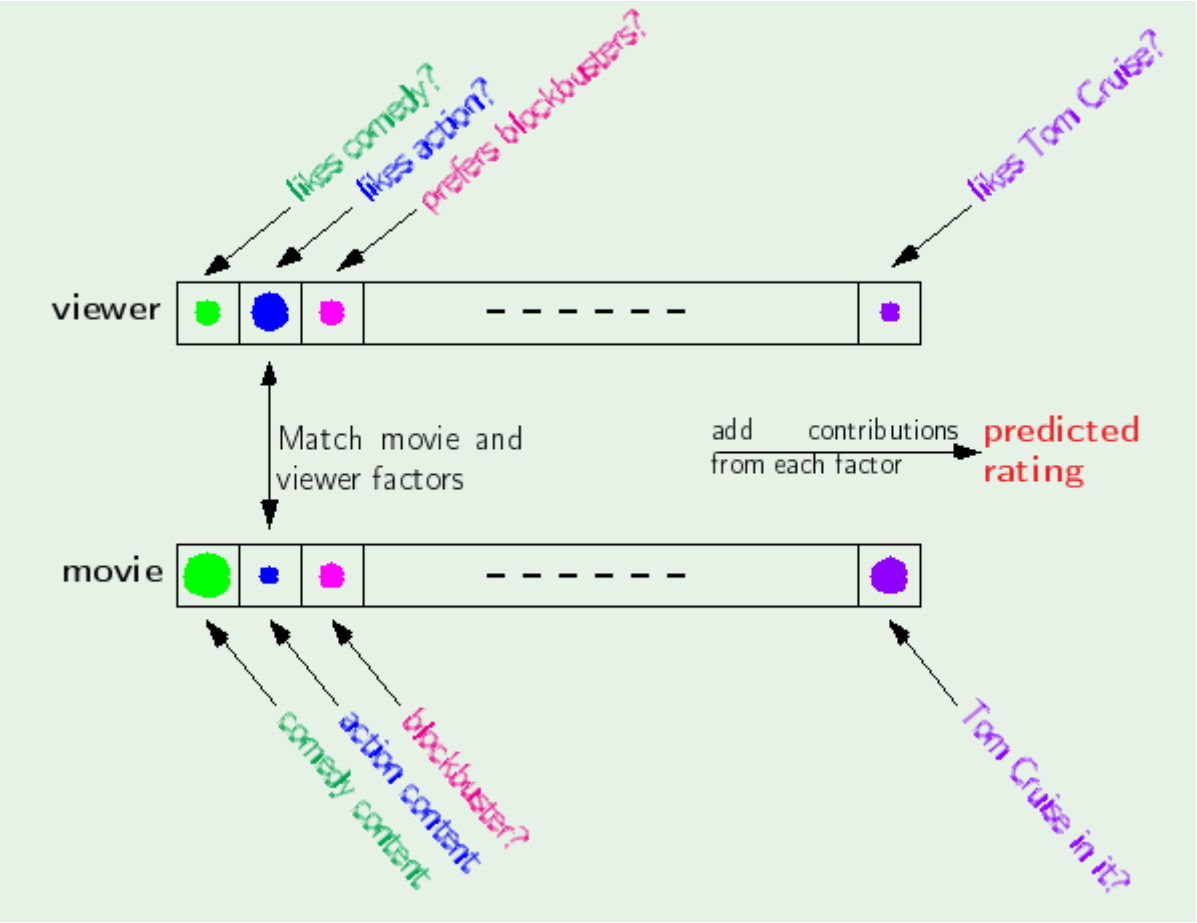
likes comedy?
likes action?
prefers blockbusters?
likes Tom Cruise?
viewer
Match movie and viewer factors
add contributions from each factor
predicted rating
movie
comedy content
action content
blockbuster?
Tom Cruise in it?

Abordagem usando aprendizagem

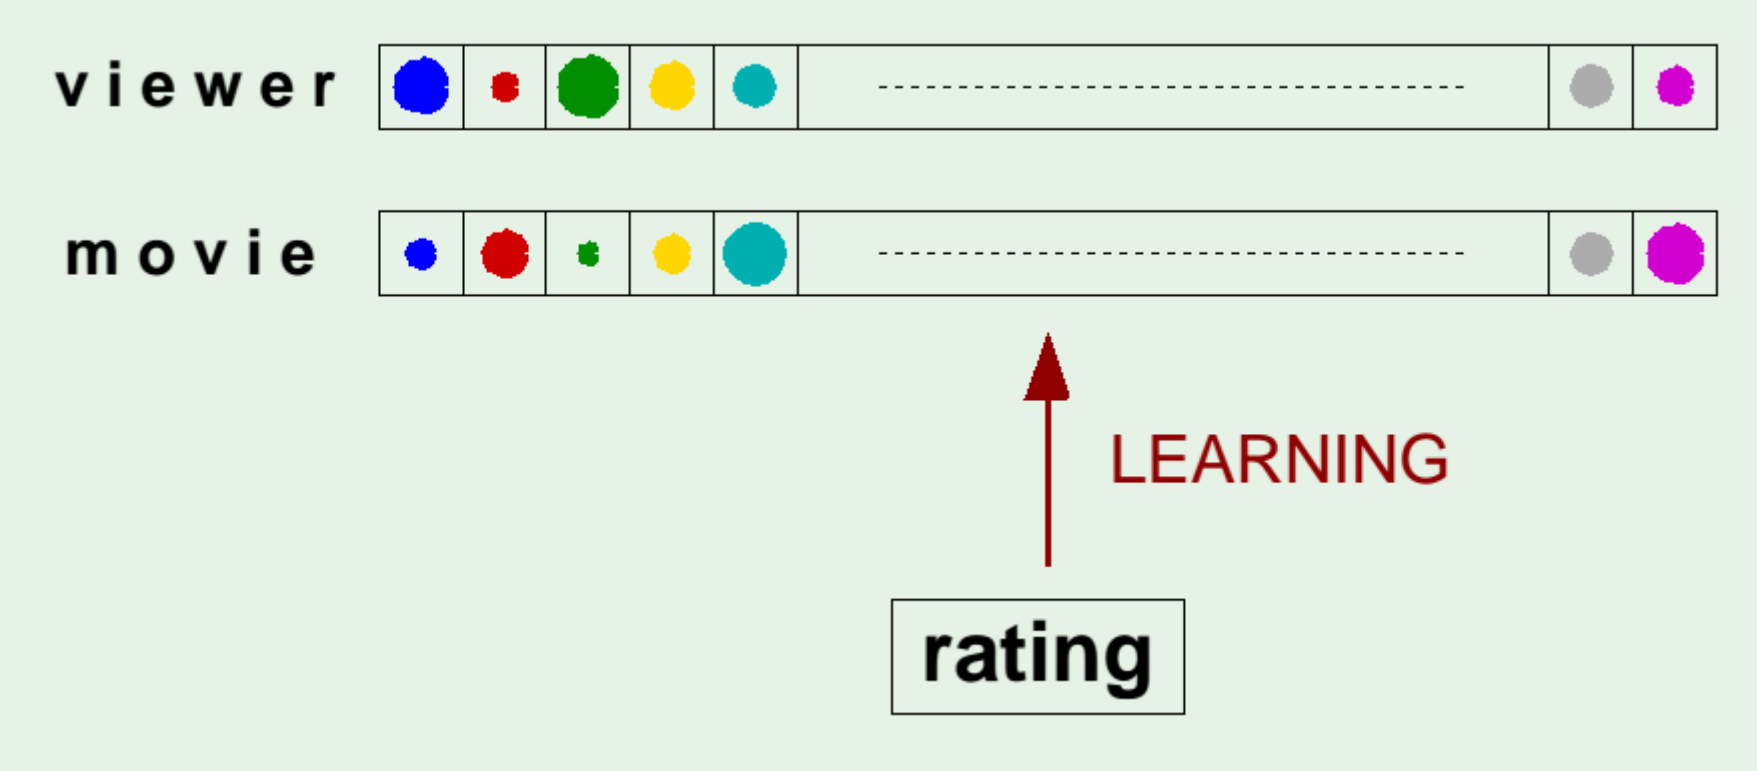

Componentes da aprendizagem

Exemplo: Aprovação de crédito

Informação cliente

Idade	23 anos
Sexo	Homem
Salário anual	€10.000
Anos na residencia	1 ano
Anos de emprego	1 ano
Dívida actual	€5.000
...	...

Aprovar crédito?

Componentes da aprendizagem

Formalização:

- Input: **x** (informação cliente)
- Output: **y** (bom/mau cliente?)
- Função alvo: **f: X** → **Y** (fórmula ideal de aprovação de crédito)
- Dados: (**x1**,**y1**), (**x2**,**y2**), …, (**xn**,**yn**) (registos históricos)

↓ ↓ ↓

- Hipótese: **g: X** → **Y** (fórmula a usar)

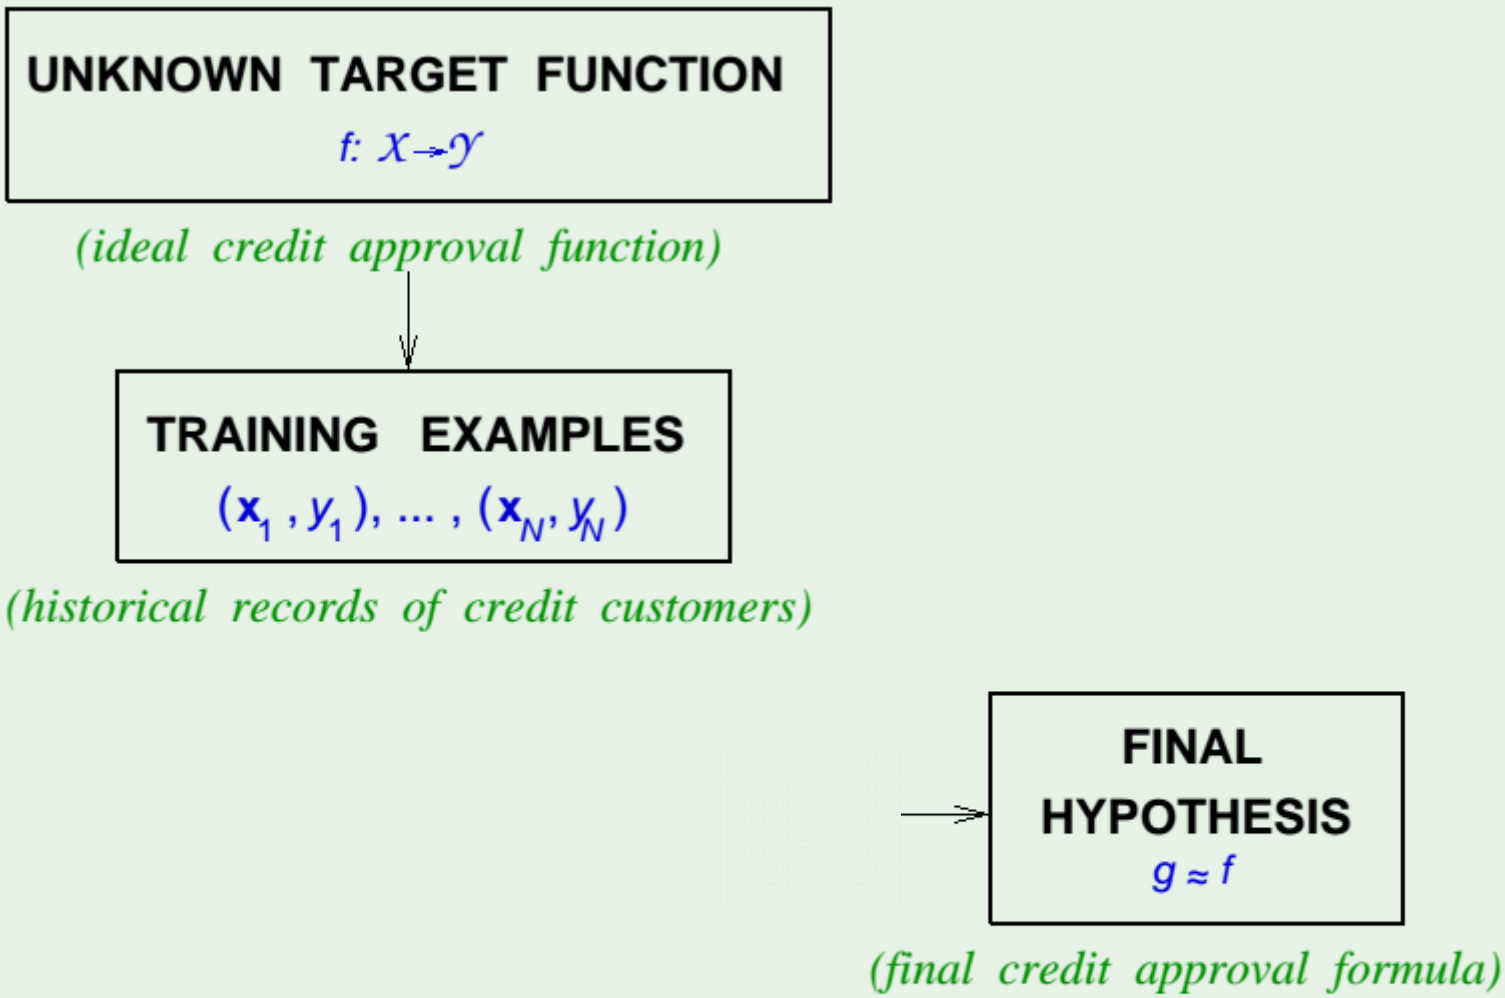
UNKNOWN TARGET FUNCTION
$f: \mathcal{X} \to \mathcal{Y}$
(ideal credit approval function)
TRAINING EXAMPLES
$(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)$
(historical records of credit customers)
FINAL HYPOTHESIS
$g \approx f$
(final credit approval formula)

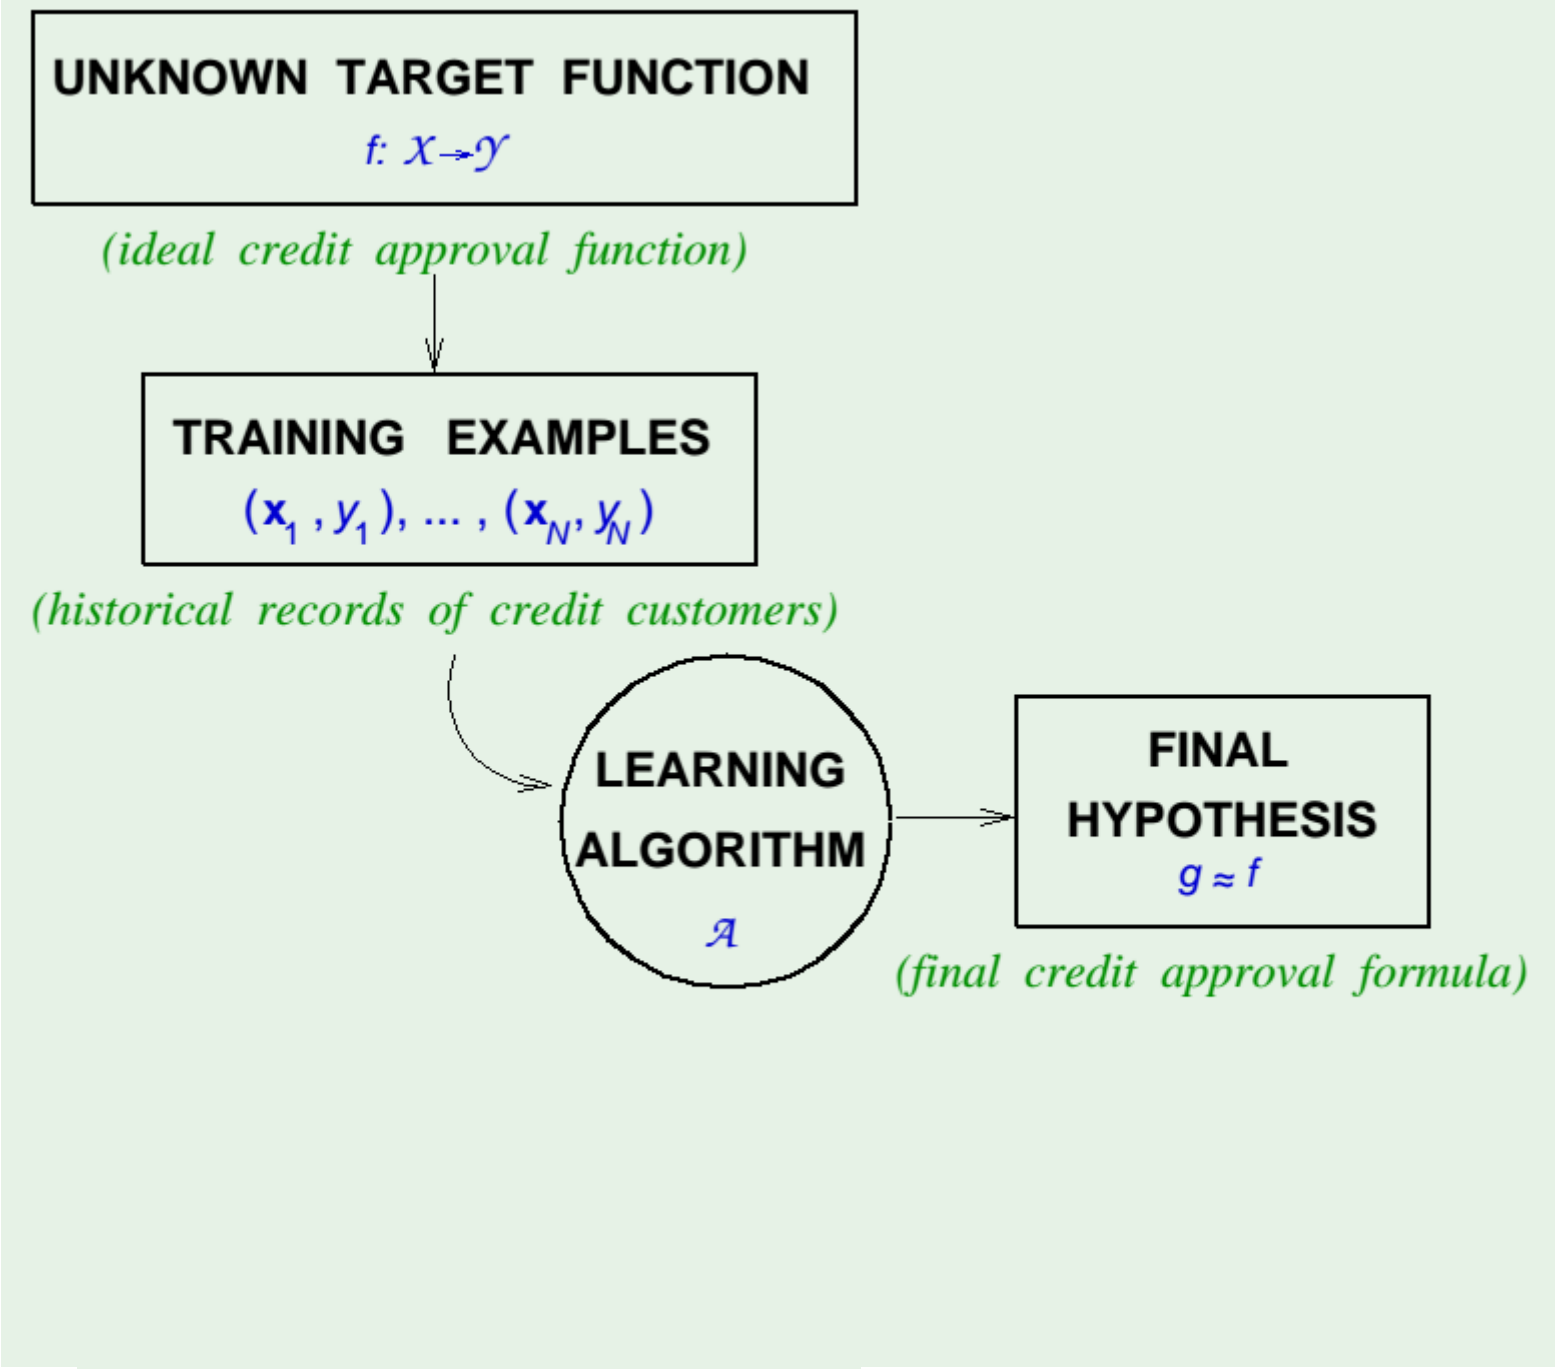
UNKNOWN TARGET FUNCTION
$f: \mathcal{X} \to \mathcal{Y}$
(ideal credit approval function)
TRAINING EXAMPLES
$(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)$
(historical records of credit customers)
LEARNING ALGORITHM
$\mathcal{A}$
FINAL HYPOTHESIS
$g \approx f$
(final credit approval formula)

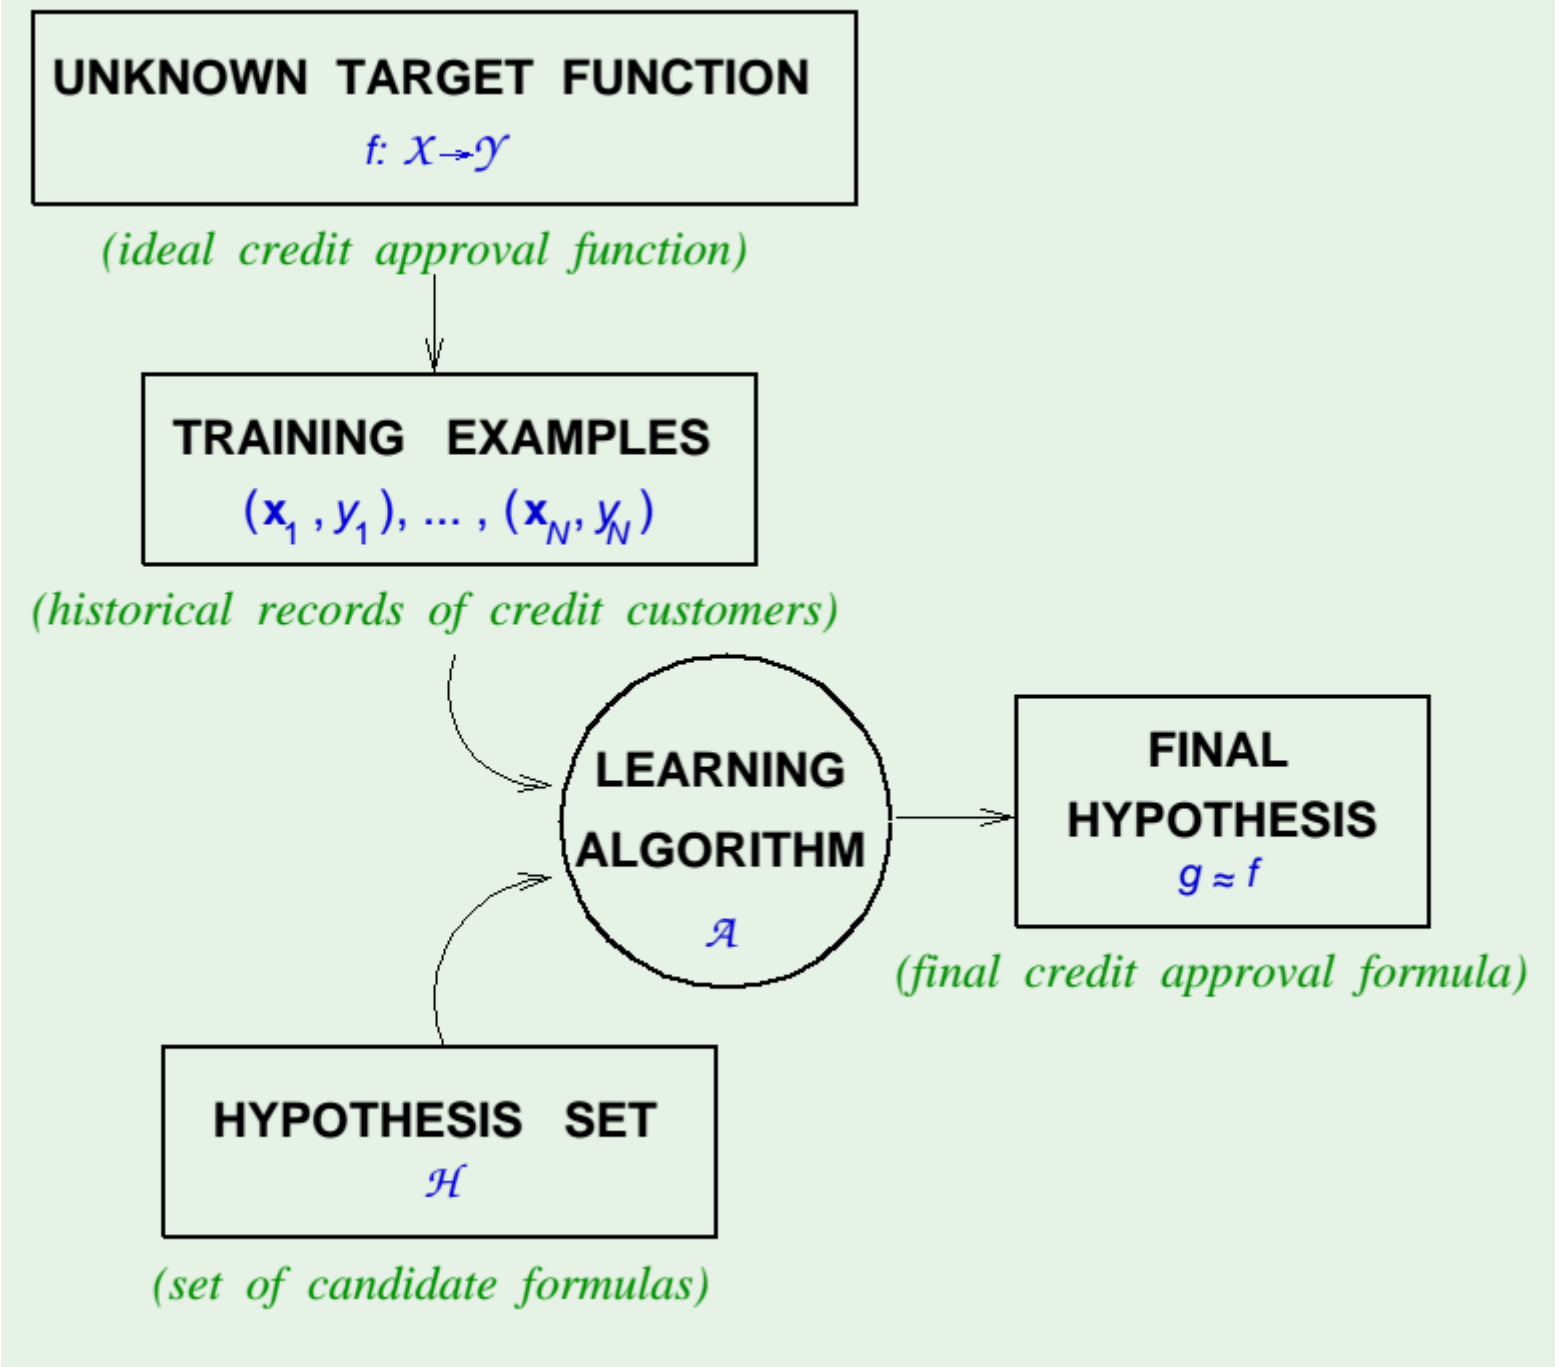
UNKNOWN TARGET FUNCTION
$f: \mathcal{X} \to \mathcal{Y}$
(ideal credit approval function)
TRAINING EXAMPLES
$(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)$
(historical records of credit customers)
LEARNING ALGORITHM
$\mathcal{A}$
FINAL HYPOTHESIS
$g \approx f$
(final credit approval formula)
HYPOTHESIS SET
$\mathcal{H}$
(set of candidate formulas)

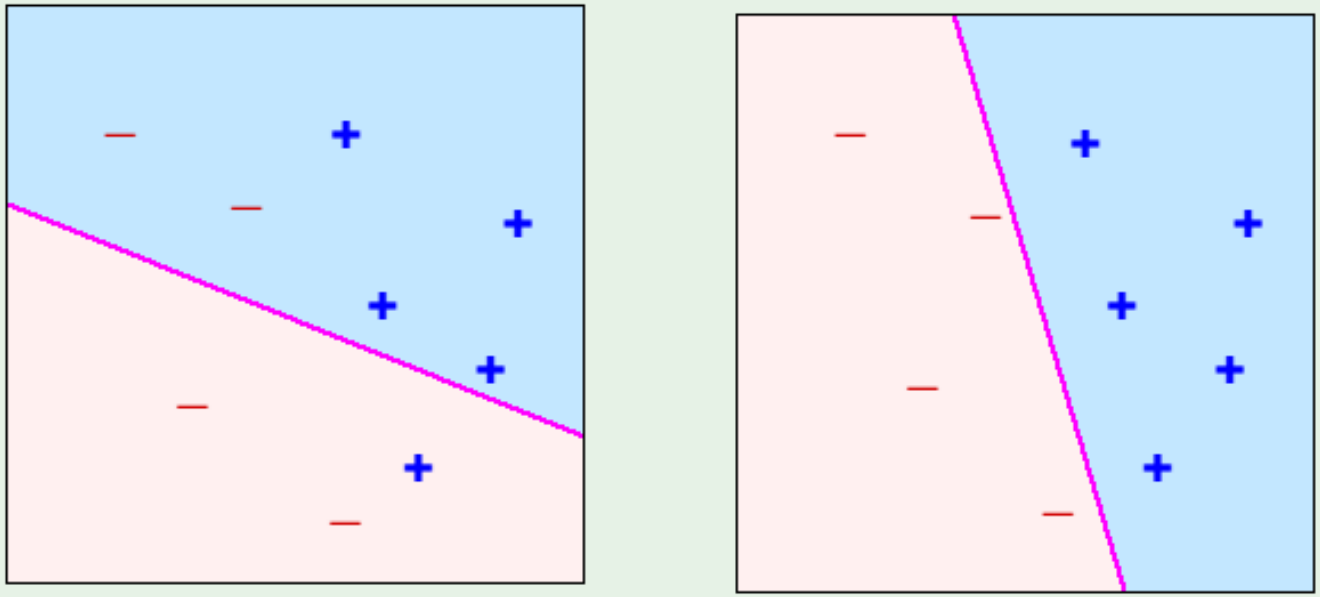

'linearly separable' data

A premissa central da aprendizagem

“usar um conjunto de observações para descobrir o processo subjacente”

Premissa geral => muitas variações

A premissa central da aprendizagem

“usar um conjunto de observações para descobrir o processo subjacente”

Premissa geral => muitas variações

- Supervised learning
- Unsupervised learning
- Reinforcement learning

Supervised learning

Exemplo de máquinas de venda de refrigerantes: reconhecimento de moedas

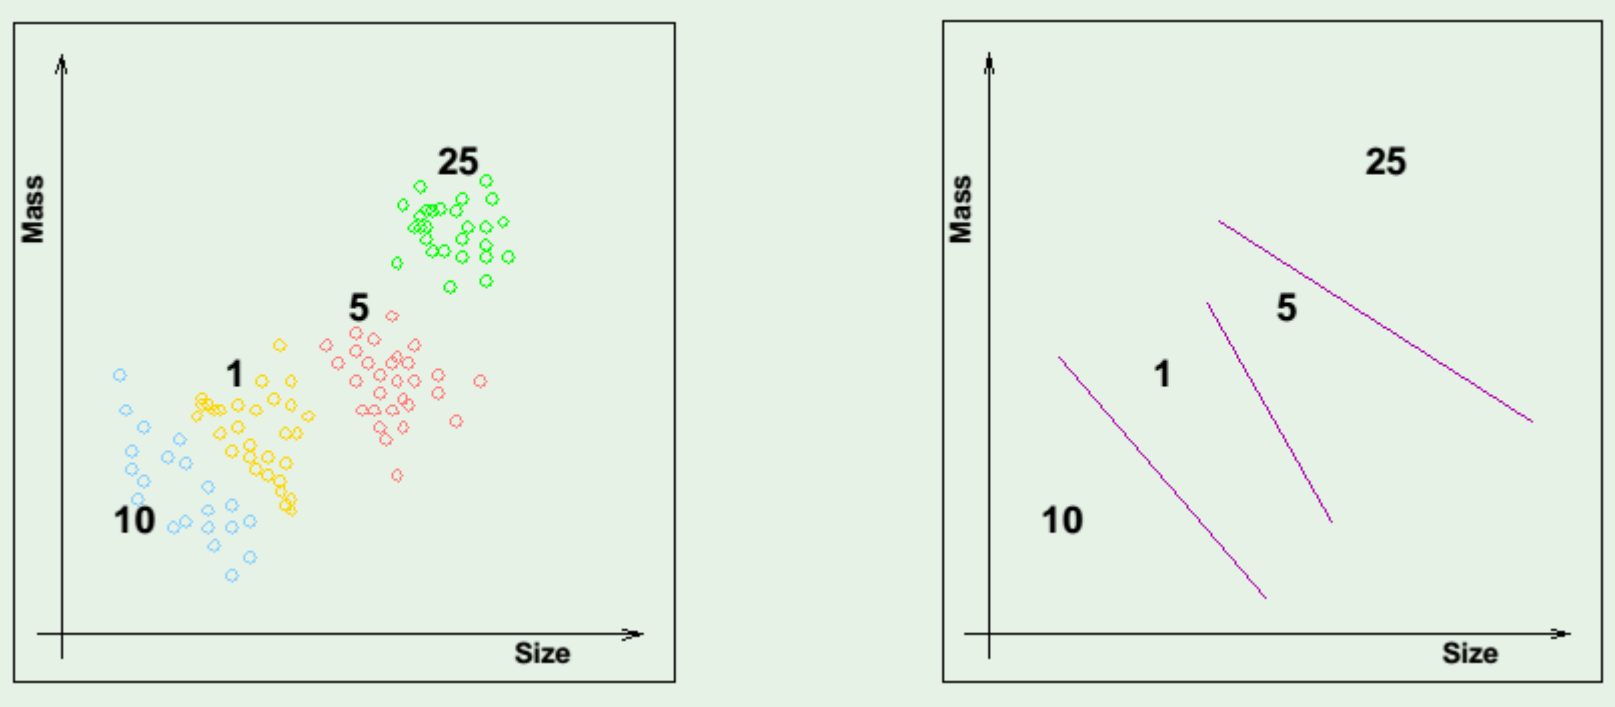

Unsupervised learning

Em vez de (input, output correcto),

Unsupervised learning

Em vez de (input, output correcto), temos (input, ?)

Unsupervised learning

Em vez de (input, output correcto), temos (input, ?)

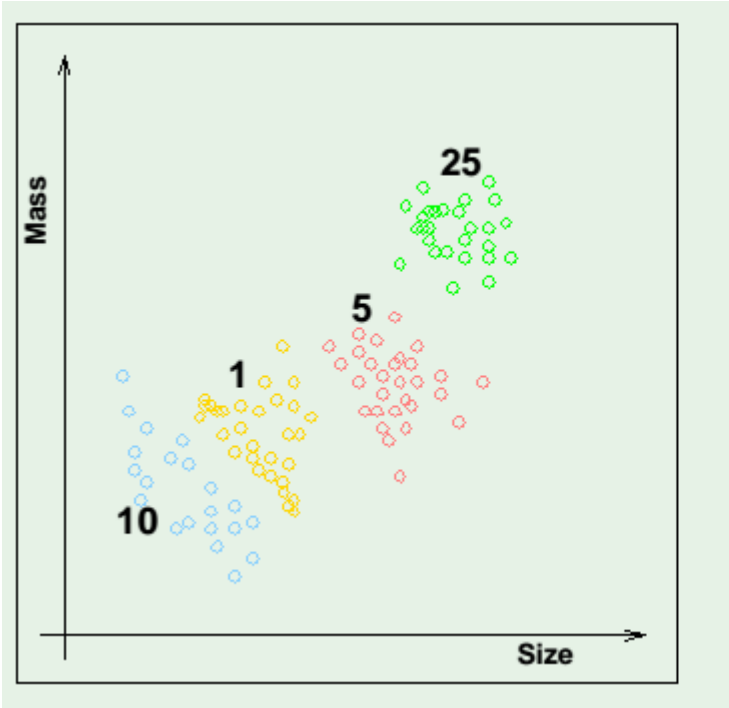

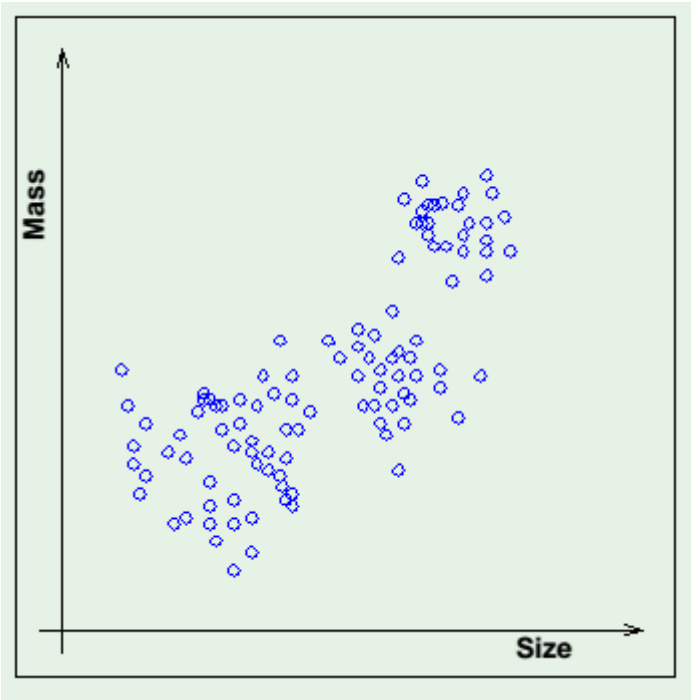

Reinforcement learning

Em vez de (input, output correcto),

Reinforcement learning

Em vez de (input, output correcto),

temos (input, algum output,

Reinforcement learning

Em vez de (input, output correcto),

temos (input, algum output, avaliar o output)

Reinforcement learning

Em vez de (input, output correcto),

temos (input, algum output, avaliar o output)

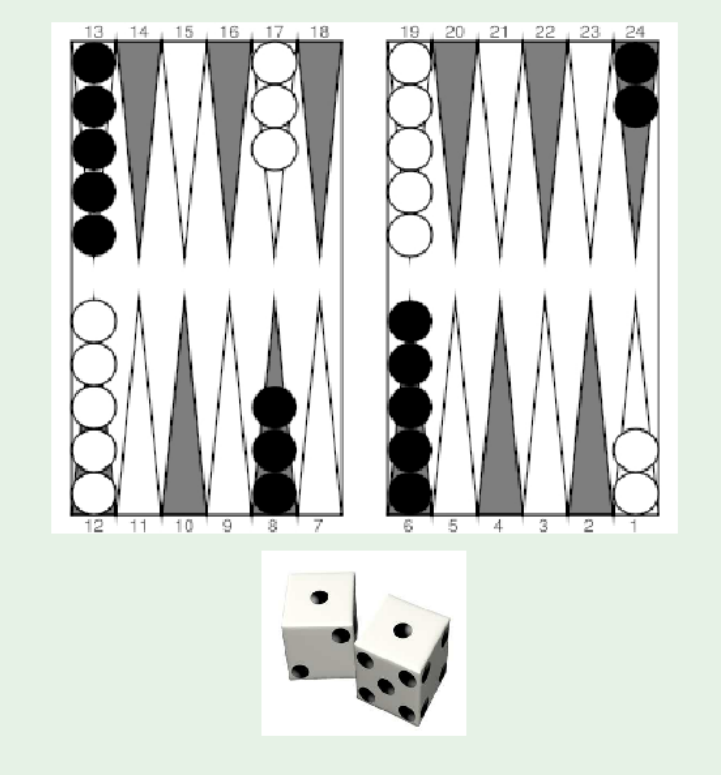

Modelos ML

- K-nearest neighbor
- SVM
- Boosted Decision Trees
- Neural networks
- Naïve Bayes
- Bayesian network
- Logistic regression
- Randomized Forests
- RBMs
- Etc.

scikit-learn algorithm cheat-sheet

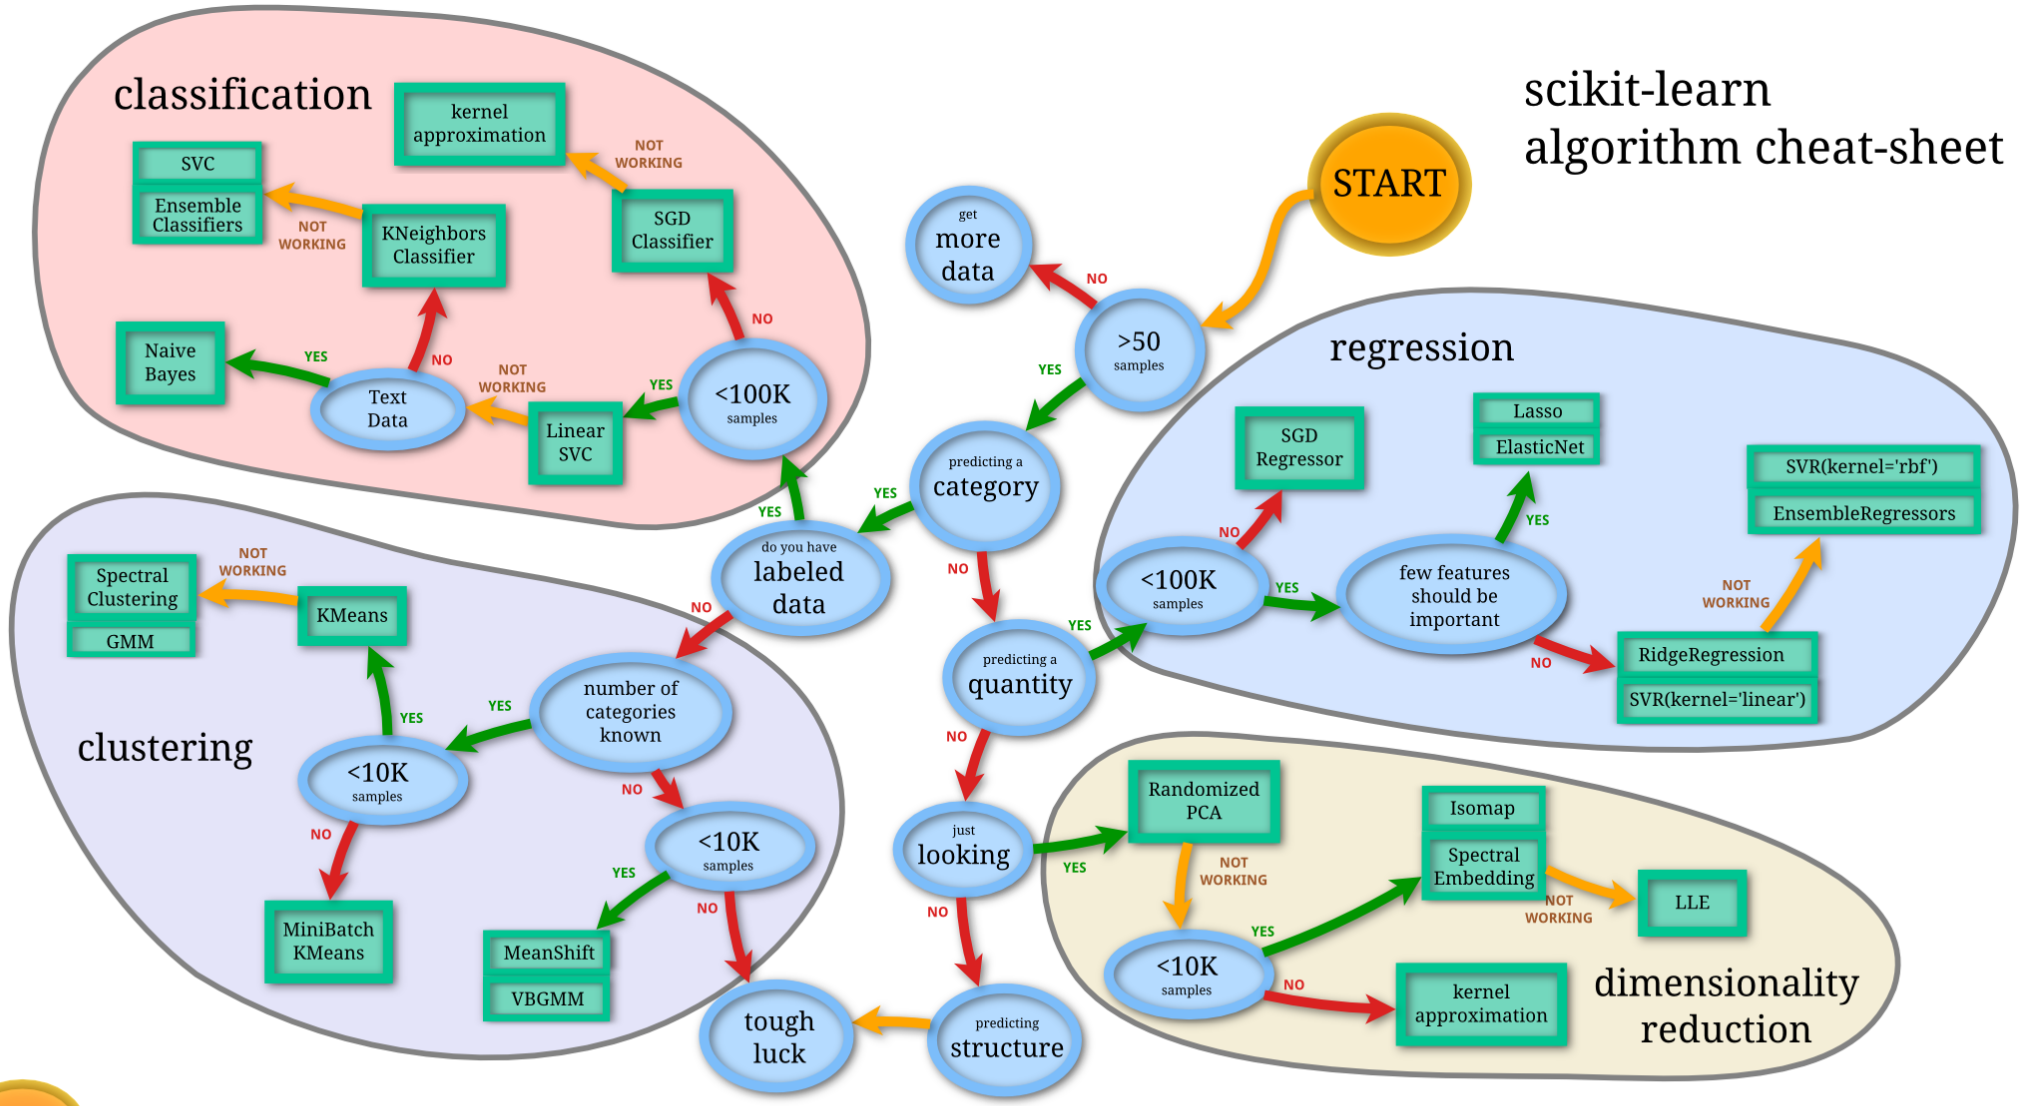

Back

scikit learn

Deep Learning
attitude
teaching
academic
intelligent
smart
competent
academy
seminar
talent
brain
mind
knowledge
wisdom
information
creative
motivation
potential
university
business
improvement
experience
possible
internet
inspiration
skill
grow
learn
success
successful
graduate
achievement
challenge
hope
school
improve
motivate
leadership
elearning
college
study
education
ability
read
career
motivational
goal
develop
training
growth
educate
possibility
inspire
solution
vision
positive
student
confident

Deep Learning

- Mudança do panorama do estado da arte:
  - Processamento de linguagem *(Natural language processing)*
  - Reconhecimento de fala *(Speech recognition)*
  - Visão Computacional *(Computer vision)*
  - Robótica *(Robotics)*
  - Biologia computacional *(Computational Biology)*

Machine Learning tradicional

Hand-crafted Features

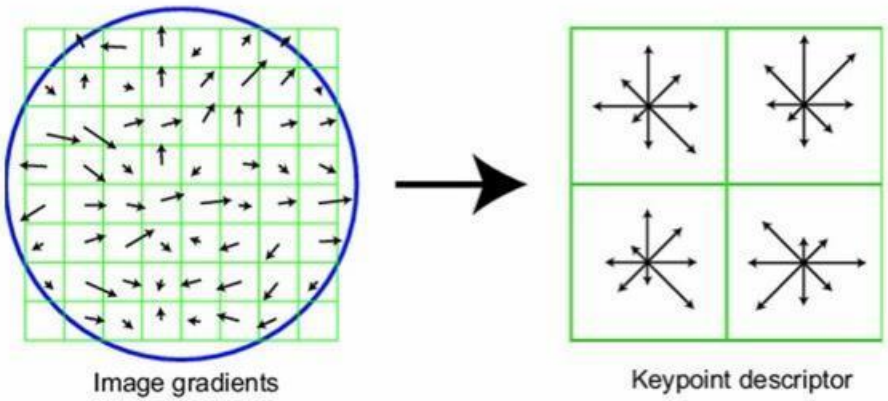

SIFT / HOG

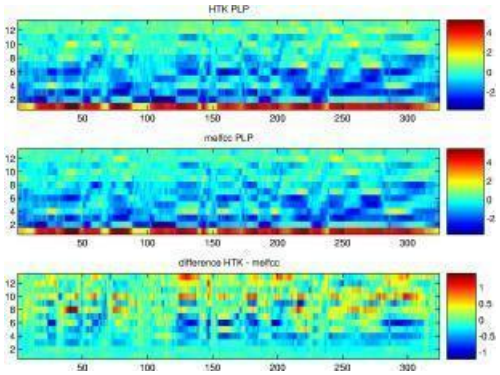

MFCC

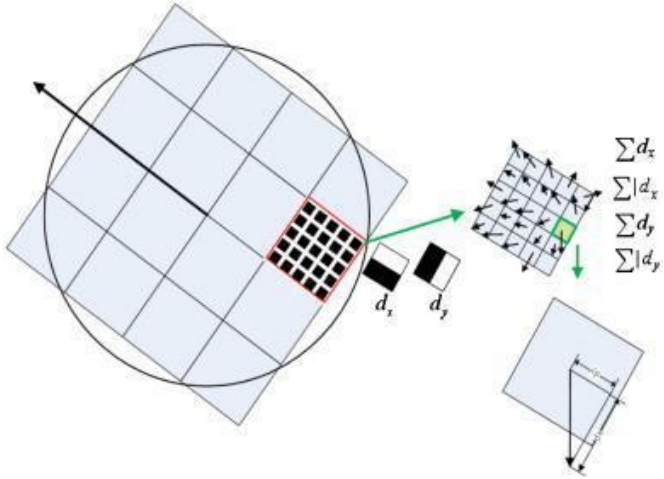

SURF

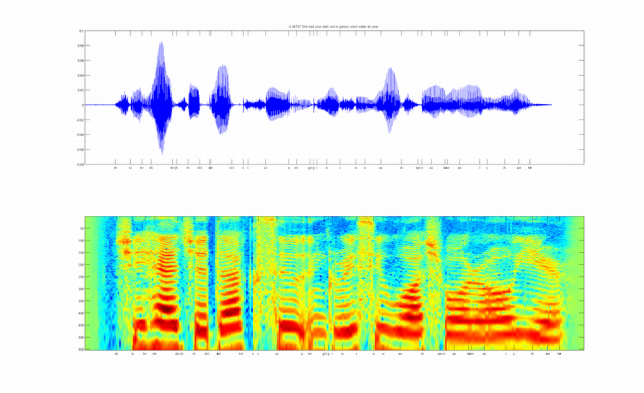

Espectograma

ML Tradicional

- *Feature Engineering* + [classificador favorito]
- Passos:
  - Encontrar um sítio onde se possam encontrar boas *features*
  - Extrair essas *features* dos dados
  - Agrupar todas as *features* e digeri-las através de
    - Logistic regression
    - Decision trees, random forests, boosting
    - Support Vector Machines

Deep learning

- Aprendizagem End-to-End
  - Não é necessário desenhar *features* à mão
- Cascata em cadeia de transformações não-lineares
- Framework geral

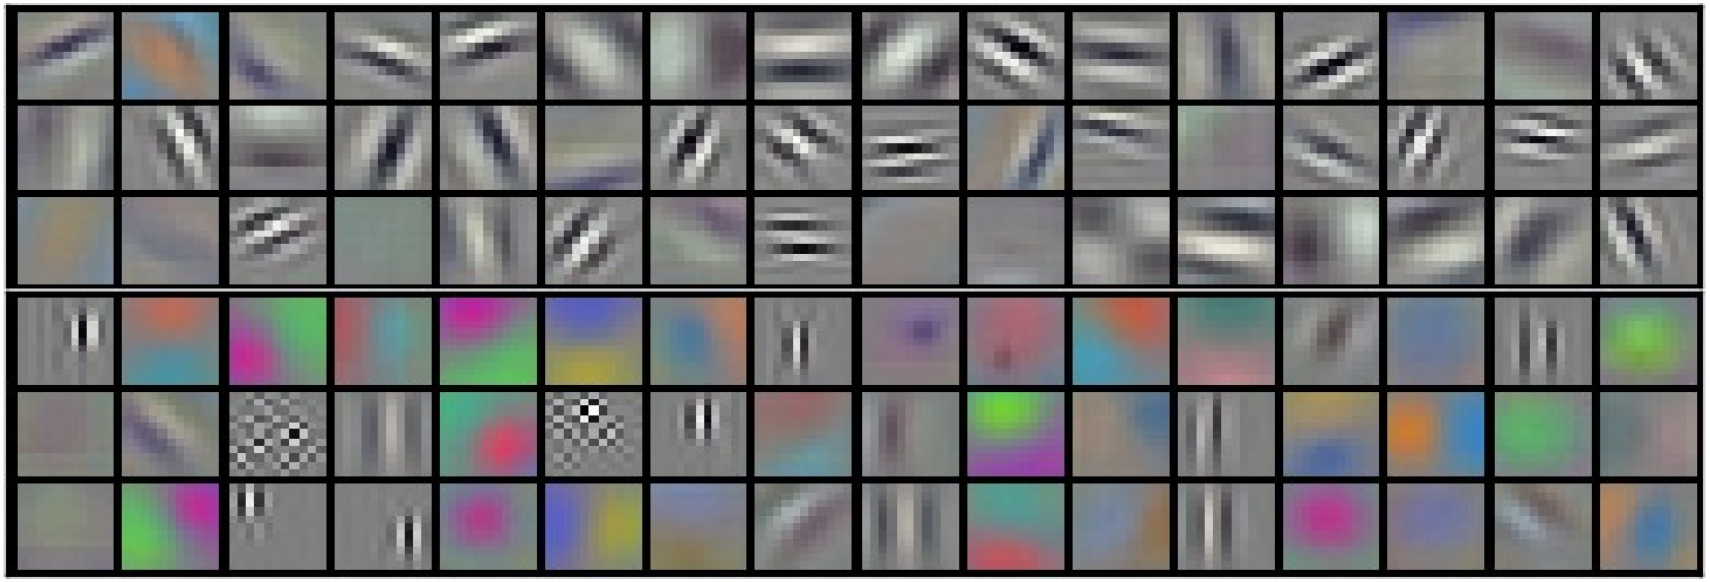

Como vencer na vida (5 passos)

- Escolher um problema
- Obter o máximo de dados possível
- Expandir o dataset ainda mais
- Treinar várias deep nets
- Ensemble

Como vencer na vida (5 passos)

- Escolher um problema
- Obter o máximo de dados possível
- Expandir o dataset ainda mais
- Treinar várias deep nets
- Ensemble

Deep Neural Networks

Neural Network (Redes Neuronal)

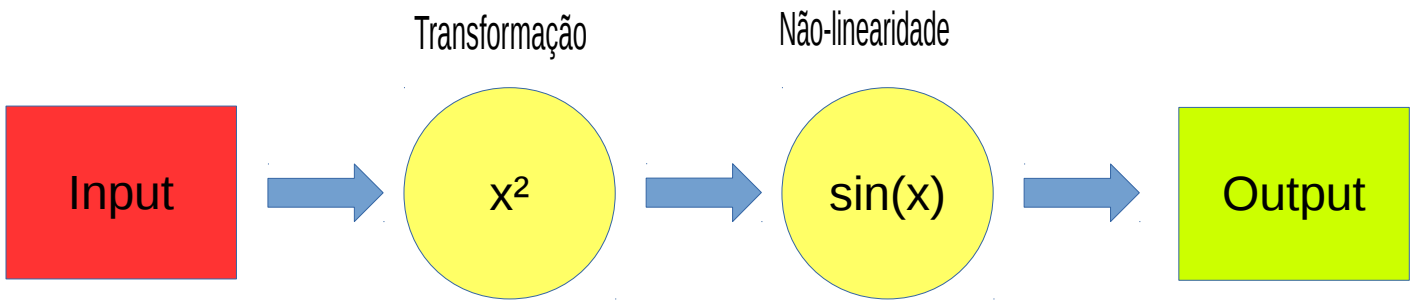

Deep Neural Networks

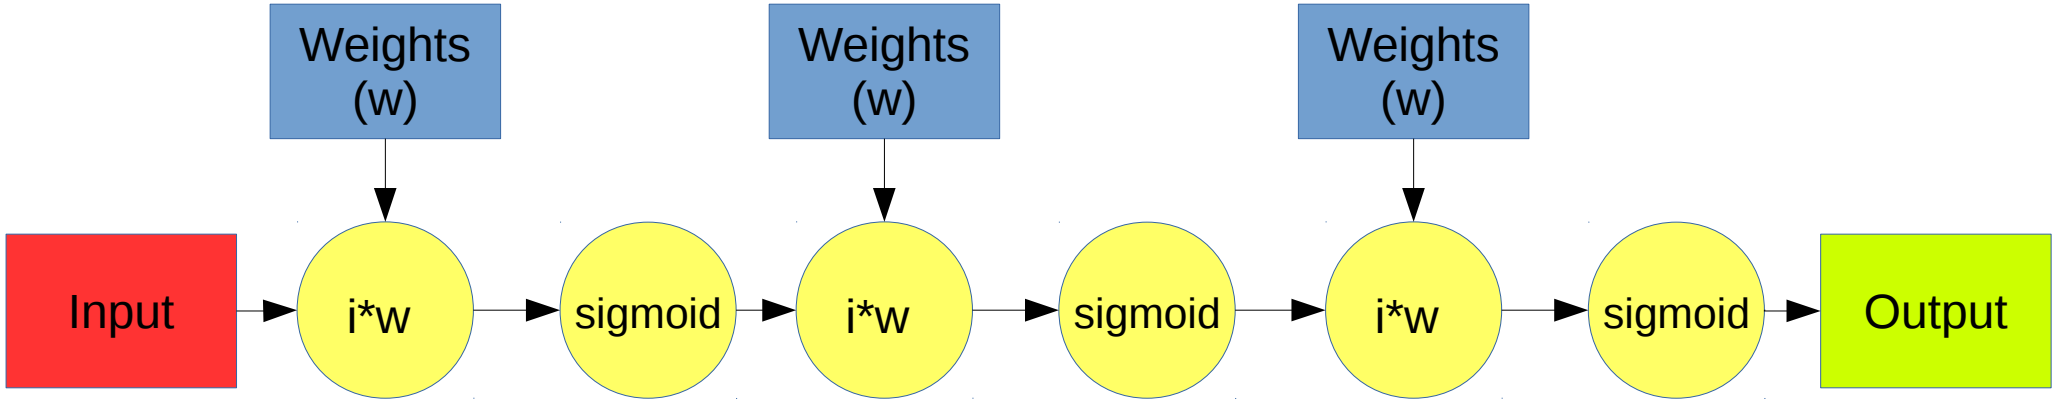

Neural networks vs Gráfos computacionais

- Neural networks são treinadas através de back-propagation
- Cada nó tem um f(x) e df(x)/dx

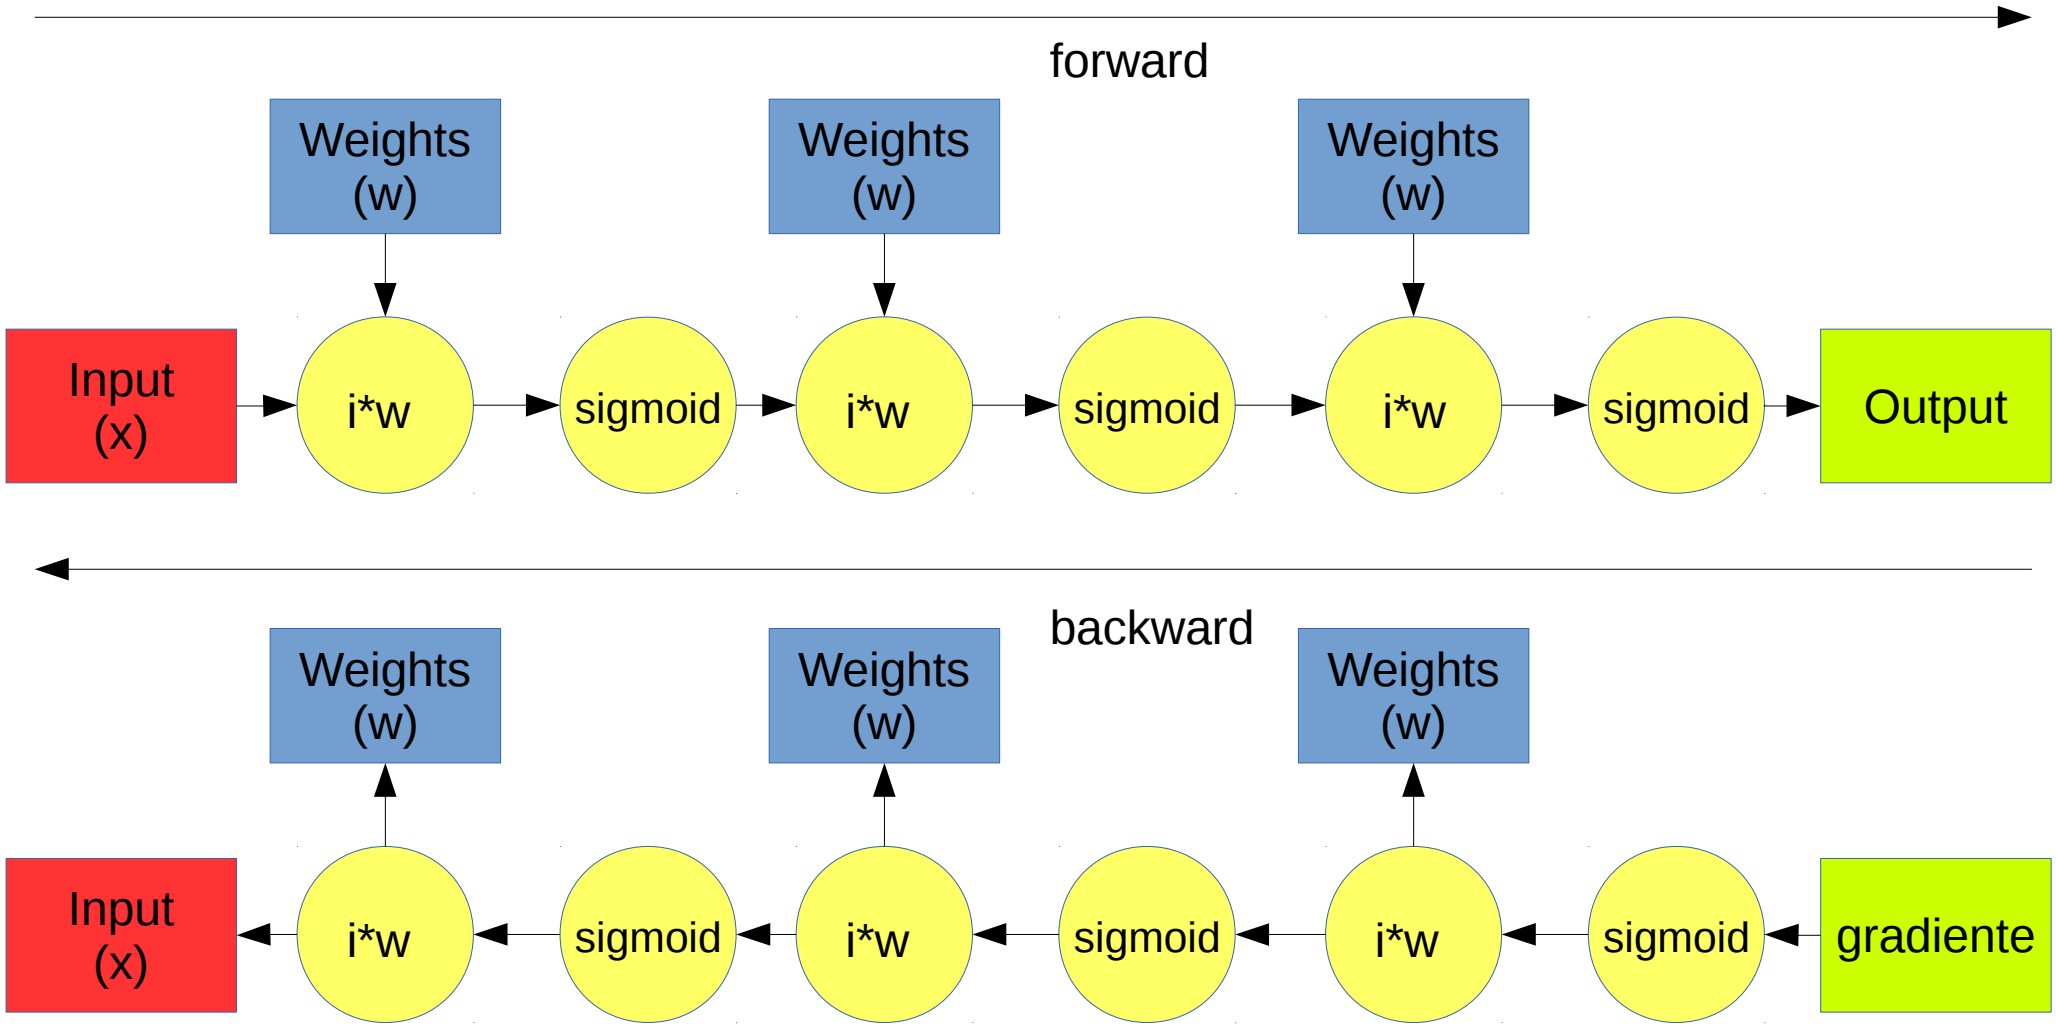

Convolutional Neural Networks

(CNNs / ConvNets)

Convolutional Neural Networks

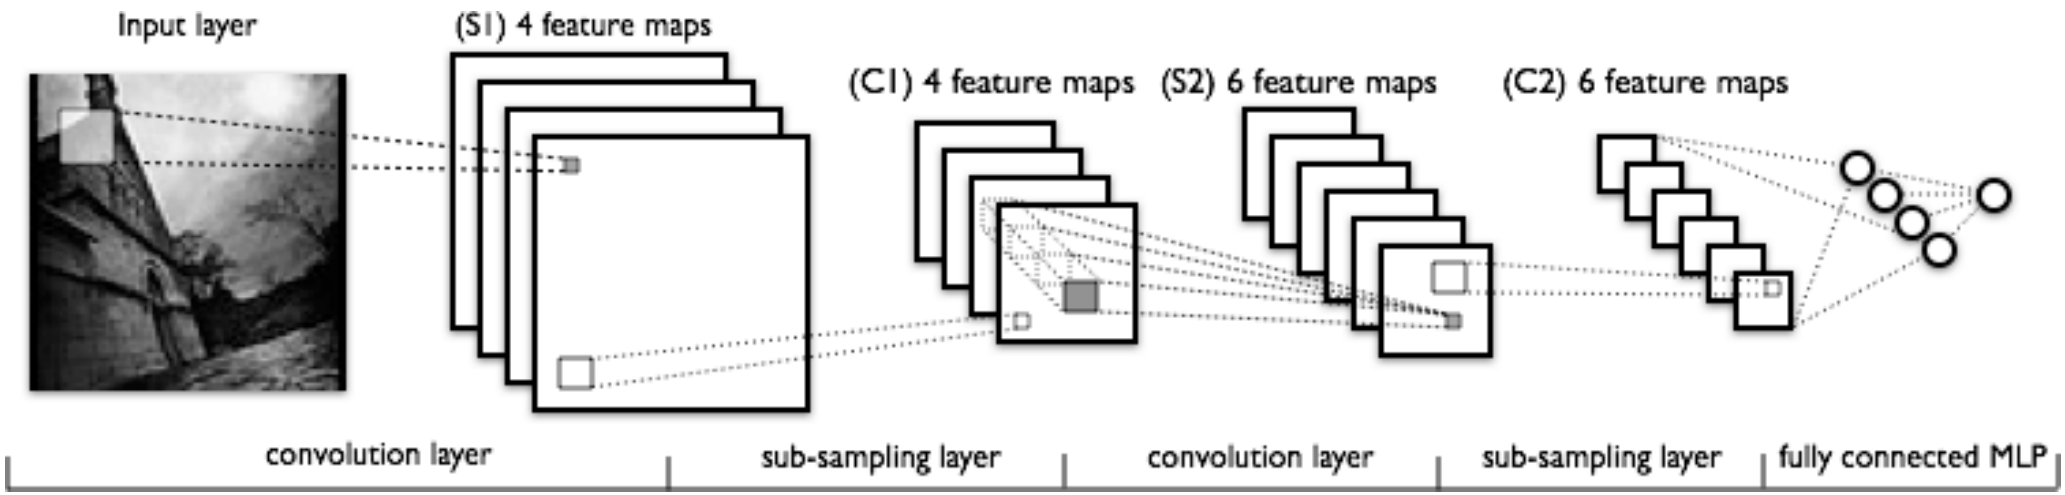

Resultados ImageNet classification 2012

- 1M training images, 1K categories, top-5 error

Human performance	~3-5%
Deep-learning models	~15%
Non-deep learning models ISI, Japan Oxford, England INRIA, France University of Amsterdam, etc.	~26%

Resultados ImageNet classification 2015

- 1M training images, 1K categories, top-5 error

Human performance	~3-5%
Deep-learning models	~4.5%
Non-deep learning models ISI, Japan Oxford, England INRIA, France University of Amsterdam, etc.	~26%

State-of-the-art usando ConvNets

Segmentation and Stereo

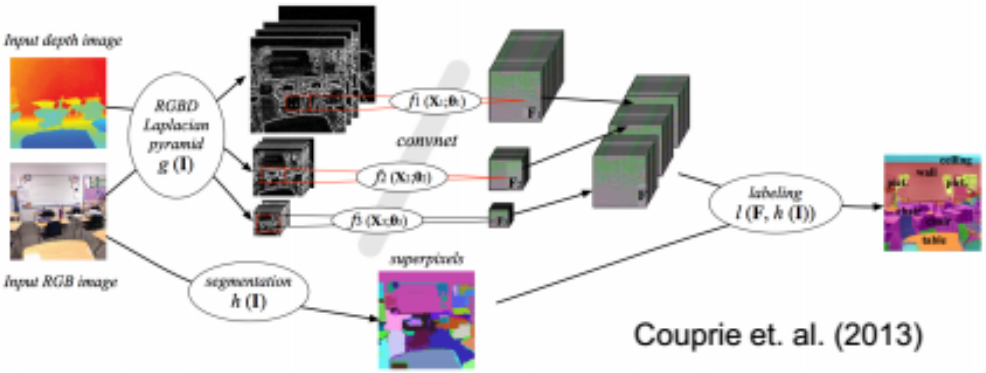

Couprie et. al. (2013)

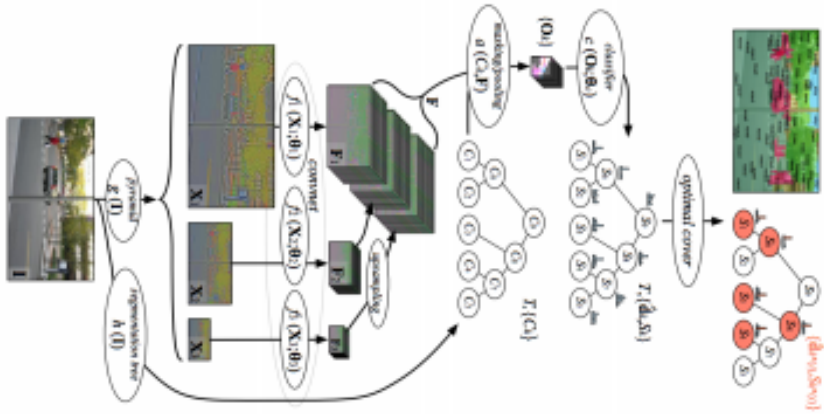

Farabet et. al. (2012)

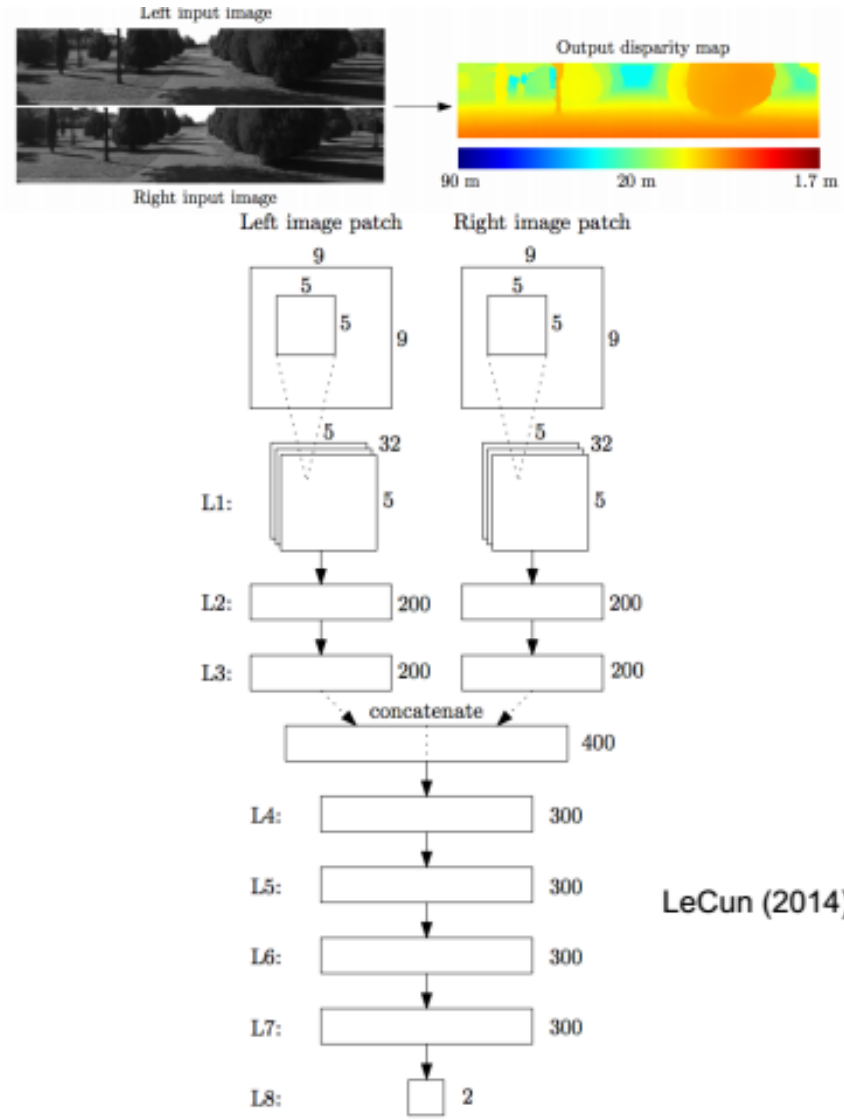

LeCun (2014)

ConvNets + Graphical Model (Tompson et. al. 2014)

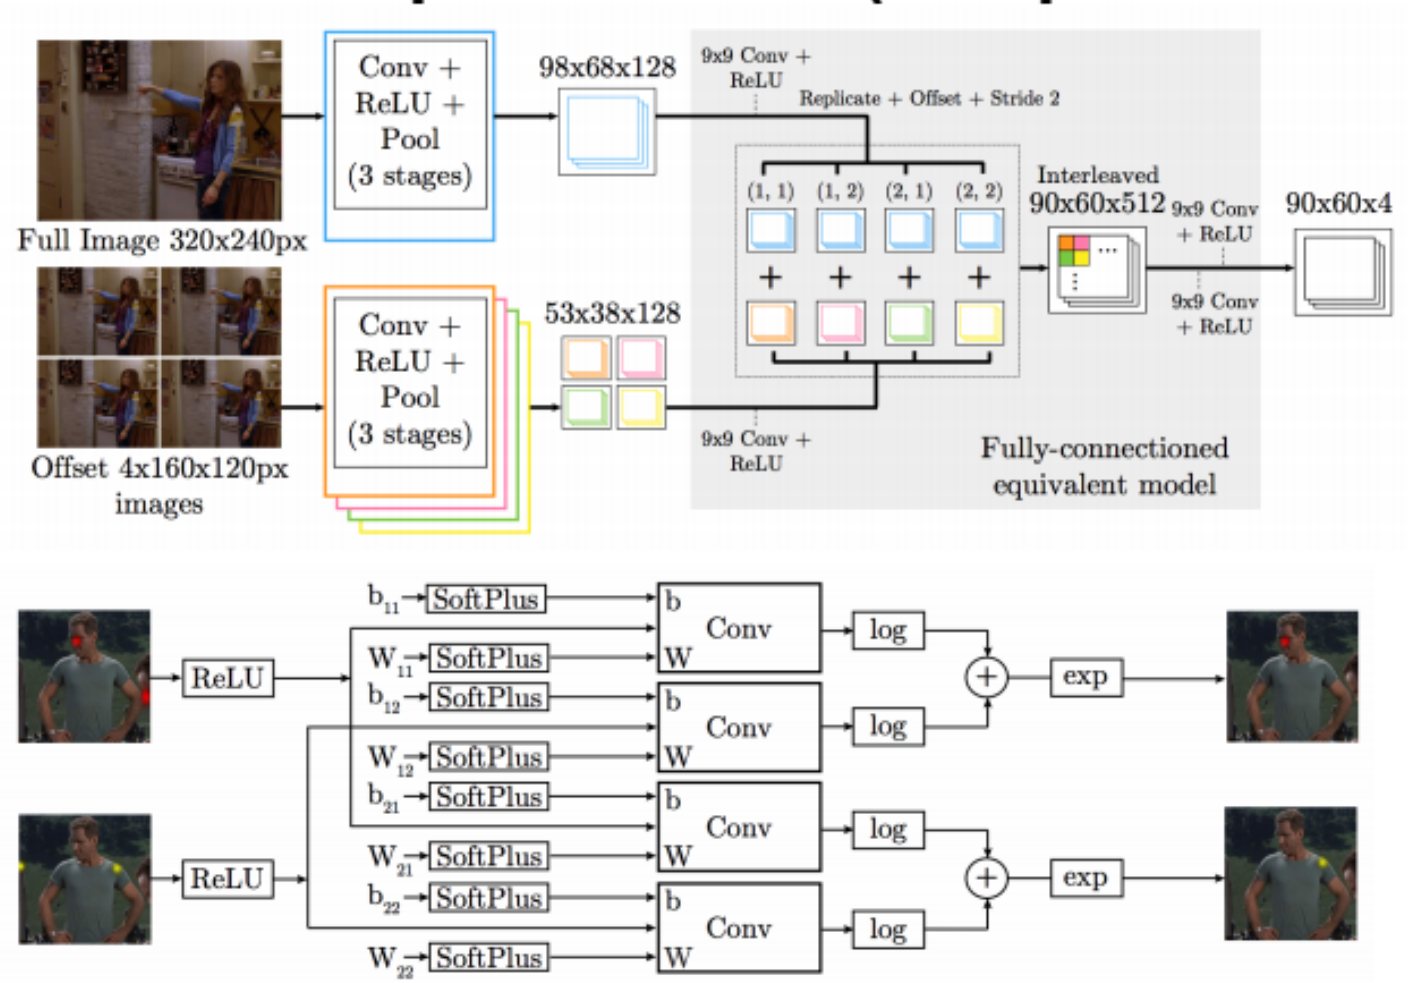

Generative Adversarial Nets

Goodfellow et. al. (2014)

ConvNets for NLP

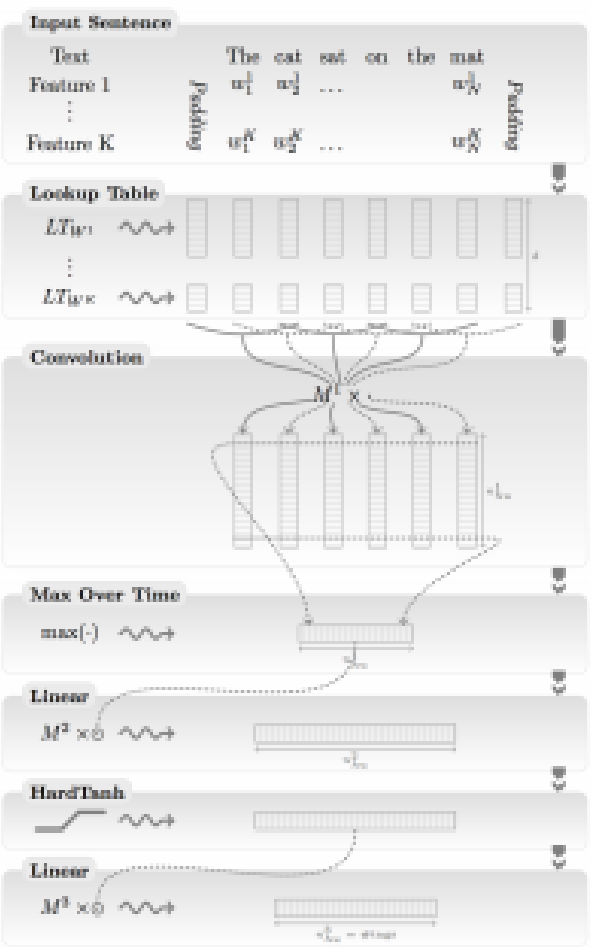

Collobert et. al.

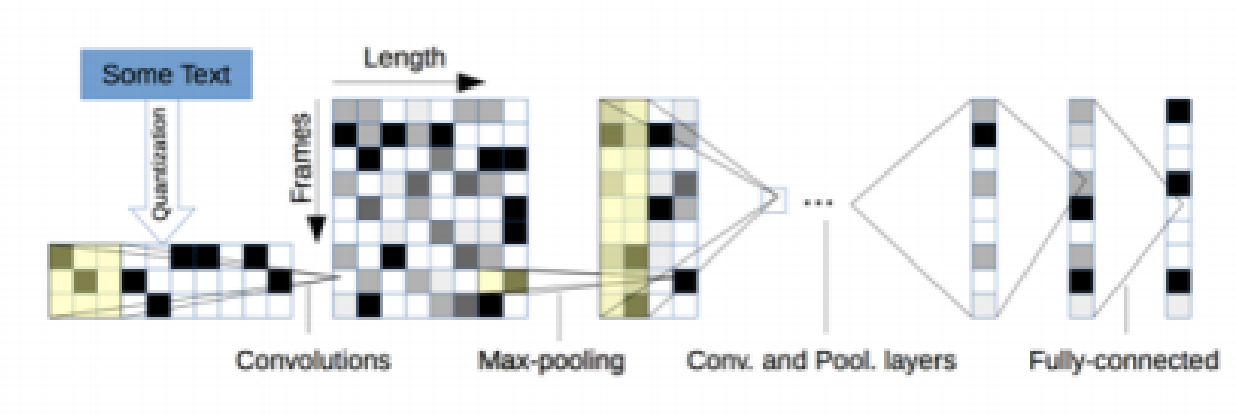

Zhang et. al.

Resultados

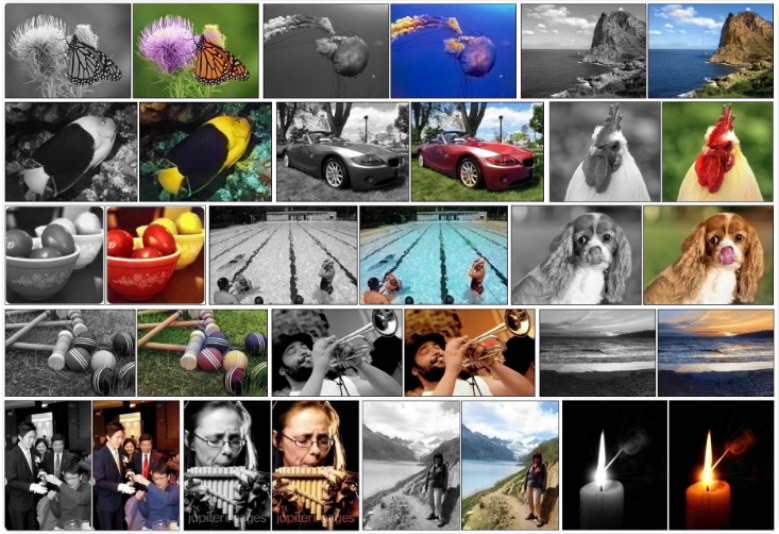

"man in black shirt is playing guitar."

"construction worker in orange safety vest is working on road."

"two young girls are playing with lego toy."

Machine Learning Mastery

Machine Learning Mastery

Machine Learning Mastery

"girl in pink dress is jumping in air."

"black and white dog jumps over bar."

"young girl in pink shirt is swinging on swing."

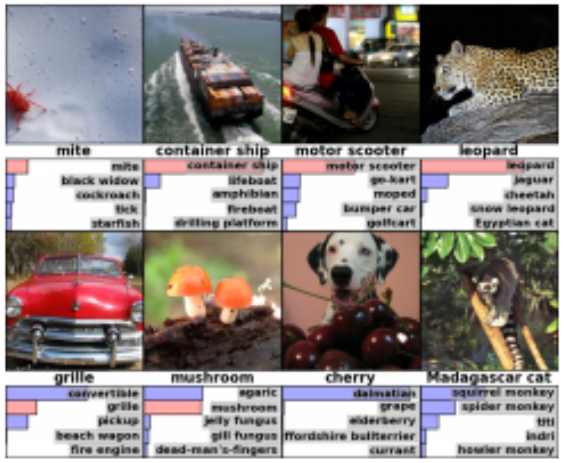

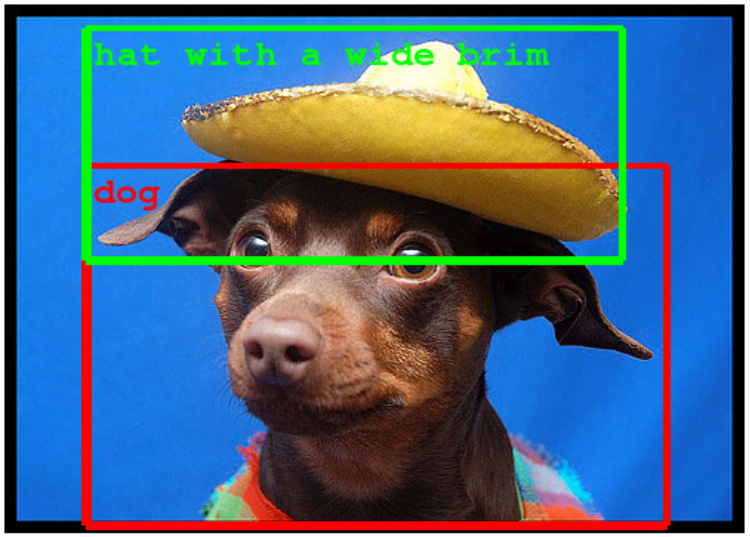

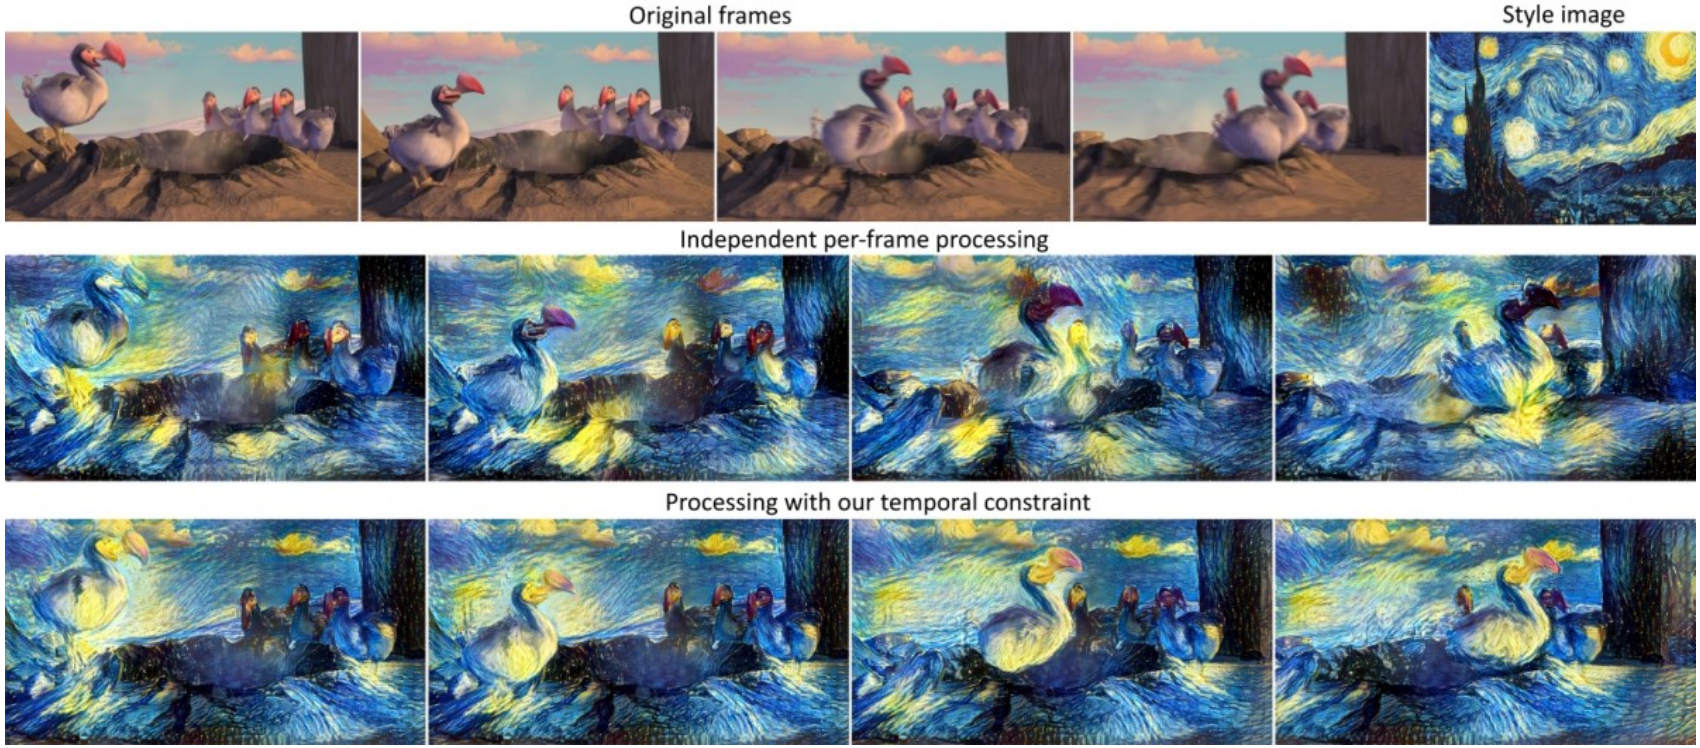
Original frames
Style image
Independent per-frame processing
Processing with our temporal constraint

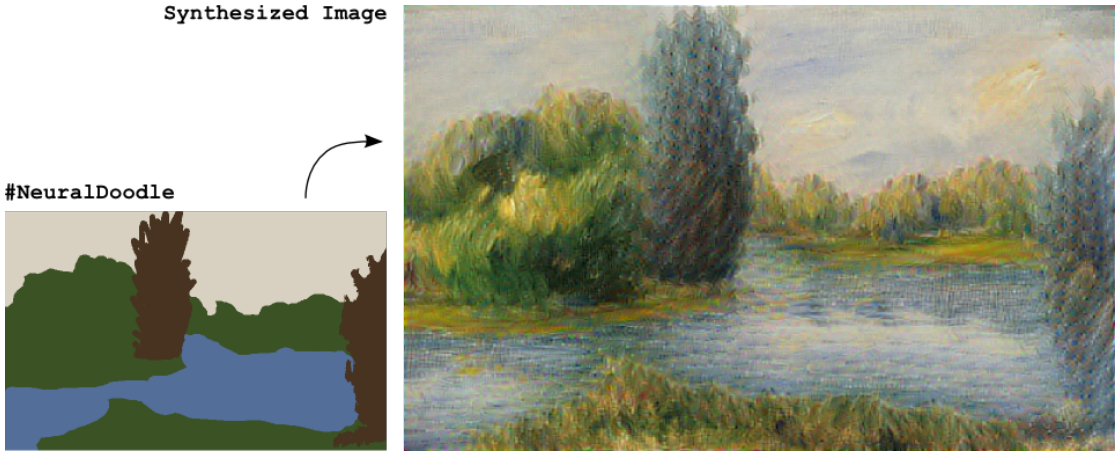
Synthesized Image
#NeuralDoodle

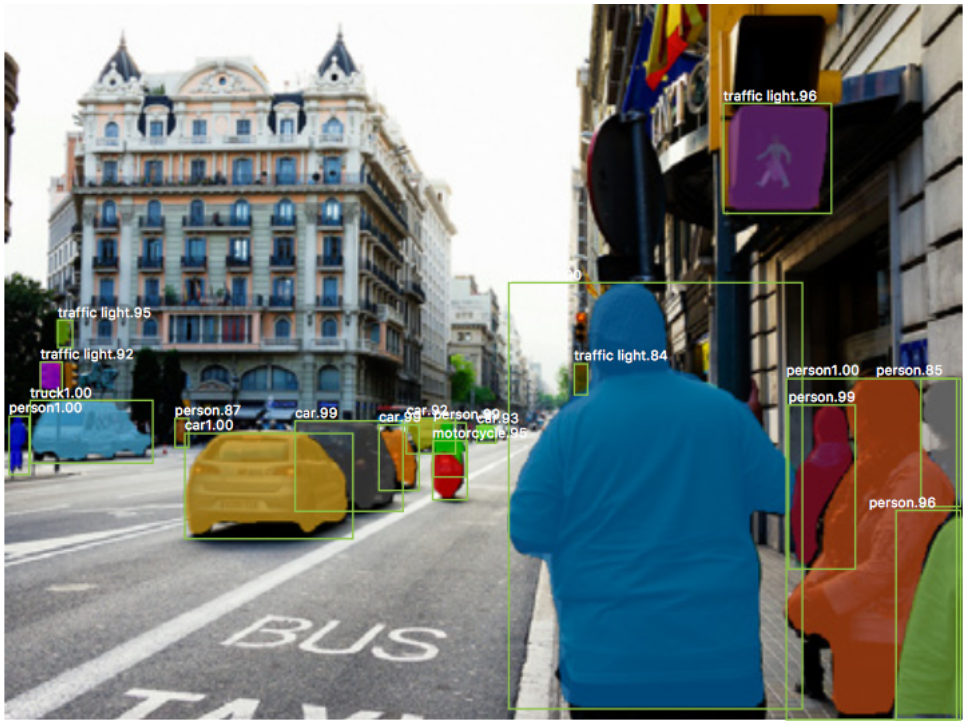
traffic light.96
traffic light.95
traffic light.92
truck1.00
person1.00
person.87
car1.00
car.99
car.92
person.93
motorcycle.95
traffic light.84
person1.00
person.85
person.99
person.96
BUS

User Interface

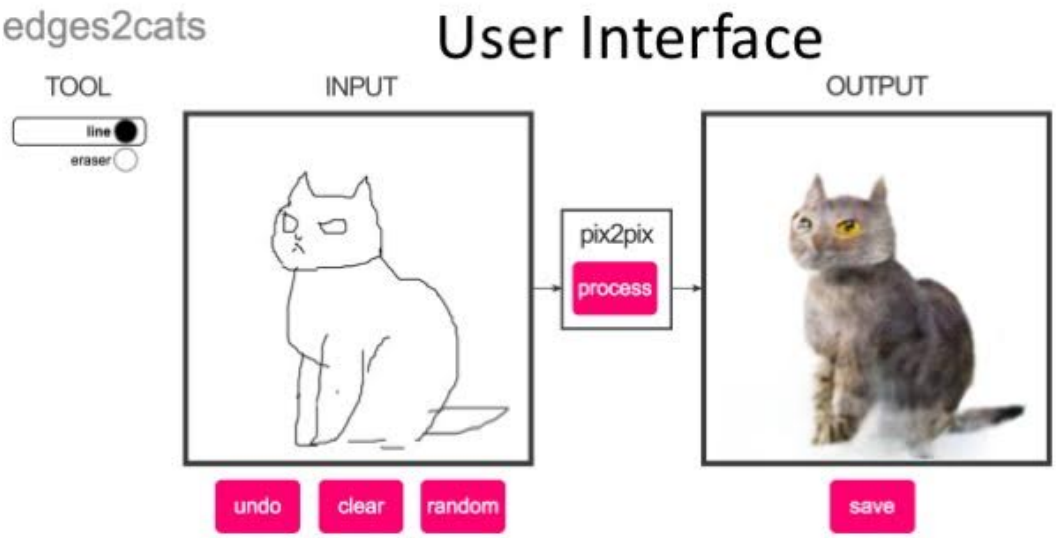

@gods_tail

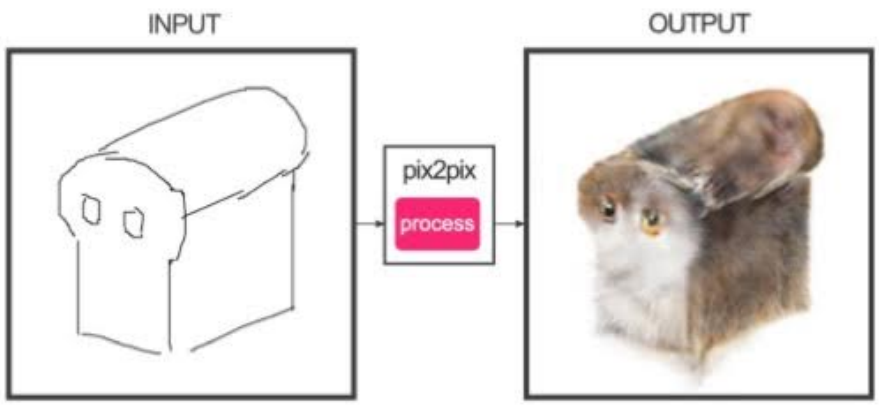

Ivy Tasi @ivymyt

Results

Vitaly Vidmirov @vvid

@ka92

Deepmind self-taught to walk

https://www.youtube.com/watch?v=gn4nRCC9TwQ

OpenAi – Dota 2

https://www.youtube.com/watch?v=92tn67YDXg0

Starcraft 2

https://www.youtube.com/watch?v=3PLplRDSgpo

Obama lip sync

https://www.youtube.com/watch?v=MVBe6_o4cMI

Toolboxes

+

Frameworks

Toolboxes Machine Learning

Linguagens Data Science

python™

julia

R

Scala

MATLAB

Linguagens Data Science

python™

Vantagens em usar Python

- Top-5 das linguagens mais importantes a dominar em 2018+
- Fácil de aprender
- Versátil
- Comunidade activa
- Enorme ecosistema de bibliotecas:
  - Encriptação
  - Redes
  - Web frameworks
  - Data science (Paridade com R)
  - Sysadmin
  - Etc.
- Linguagem interpretada (VM)
- Package manager (pip / conda)

Bibliotecas para Data Science

- Numpy
- Pandas
- Scikit-learn (ML)
- Scipy
- Matploblib, Seaborn, Bokeh, Plotly
- PySpark
- Scrapy (web scrapping)
- Ipython, jupiterlab

Frameworks Deep Learning

theano

PYTORCH

mxnet

Chainer

Microsoft CNTK

Caffe

K Keras

Caffe2

Static vs Dynamic Computational Graphs

- Static graphs:
  - *Define then run*
  - Gráfo estático
  - Mais fácil de optimizar
  - Mais fácil de parallelizar
  - Requer alocar recursos antecipadamente
  - Mais difícil fazer debug

- Dynamic graphs:
  - *Define by run*
  - Gráfo dinâmico
  - Fácil de criar qualquer tipo de arquitecturas
  - Fácil de usar qualquer tipo de input (não requer alocação de recursos à priori)
  - Mais fácil fazer debug

Caffe2

PYTORCH

Chainer

Static vs Dynamic Computational Graphs

- Static graphs:
  - *Define then run*
  - Gráfo estático
  - Mais fácil de optimizar
  - Mais fácil de parallelizar
  - Requer alocar recursos antecipadamente
  - Mais difícil fazer debug

- Dynamic graphs:
  - *Define by run*
  - Gráfo dinâmico
  - Fácil de criar qualquer tipo de arquitecturas
  - Fácil de usar qualquer tipo de input (não requer alocação de recursos à priori)
  - Mais fácil fazer debug

Caffe2 ONNX PYTORCH Chainer

Recursos online

Machine learning / Deep learning

Cursos online (grátis)

- **Edx: Learning from data Introductory Machine Learning**
  https://www.edx.org/course/learning-data-introductory-machine-caltechx-cs1156x-0
  http://work.caltech.edu/library/index.html
- Coursera: Machine learning

  https://www.coursera.org/learn/machine-learning
- **Stanford CS231n: Convolutional Neural Networks for Visual Recognition**
  http://cs231n.stanford.edu/syllabus.html
- Udacity: Deep learning
  https://www.udacity.com/course/deep-learning-nanodegree-foundation--nd101
- fast.ai:

  http://www.fast.ai/
- Outros cursos online
  http://www.deeplearningweekly.com/blog/open-source-deep-learning-curriculum/

Livros:

- Deep Learning - An MIT Press Book
  http://www.deeplearningbook.org/
- Python Machine-Learning Book
  https://github.com/rasbt/python-machine-learning-book
- Python Data Science Handbook
  https://jakevdp.github.io/PythonDataScienceHandbook/

Videos:

- MIT 6.0002 Introduction to Computational Thinking and Data Science, Fall 2016 - Introduction to Machine Learning

  https://www.youtube.com/watch?v=h0e2HAPTGF4

- Information Theory of Deep Learning: Naftali Tishby

  https://www.youtube.com/watch?v=bLqJHjXihK8)

- Youtube: Siraj Raval - Intro to Deep Learning
  https://www.youtube.com/watch?v=vOppzHpvTiQ&list=PL2-dafEMk2A7YdKv4XfKpfbTH5z6rEEj3

Papers:

- Google Brain Team

  https://research.google.com/pubs/BrainTeam.html

- FAIR - Facebook Artificial Intelligence Research

  https://research.fb.com/category/facebook-ai-research-fair/

- Microsoft Research

  https://www.microsoft.com/en-us/research/group/deep-learning-group/

GitHub:

- https://github.com/hangtwenty/dive-into-machine-learning
- https://github.com/josephmisiti/awesome-machine-learning
- https://github.com/songrotek/Deep-Learning-Papers-Reading-Roadmap/blob/master/README.md
- https://github.com/RedditSota/state-of-the-art-result-for-machine-learning-problems

Blogs:

- reddit: Machine learning
  https://www.reddit.com/r/MachineLearning/
- fastml
  http://fastml.com
- Open AI
  https://blog.openai.com/

Fim